

KV Cache 최적화 기술 다관점 평가 시스템 설계서

팀원: P209-곽민규, P213-김선정, P229-이지원, P231-임유리, P240-현용찬

1. 대상 기술 및 문제 정의

1.1 문제 정의

데이터센터, 클라우드 LLM 서버에서는 문맥 길이와 동시 요청 수가 증가하면서 KV cache가 차지하는 GPU 메모리도 증가한다.

본 프로젝트는 이 문제를 서로 다른 계층에서 해결하는 두 기술을 조사하고, 기술 성숙도, 시장성, 이해관계자, 도메인 적용성이라는 네 관점으로 비교하는 시스템을 구축한다.

핵심 평가 질문은 다음과 같다.

KV cache 크기를 줄이는 MLA와 외부 메모리 계층을 확장하는 ITME는 데이터센터, 클라우드 LLM 서버에서 각각 어떤 효과와 도입 조건을 가지며, 평가 관점에 따라 기대와 한계가 어떻게 달라지는가?

기술 자체를 구현하거나 동일 하드웨어에서 직접 벤치마크하는 것이 아니라, 논문과 외부 자료의 근거를 수집·분석하는 Multi-Agent RAG 시스템을 개발한다.

1.2 대상 기술 및 선정 이유

구분	대상 기술	접근 방식	선정 이유
SW, 모델 아키텍처	DeepSeek-V2의 MLA	저차원 잠재 표현을 이용한 KV cache 압축	메모리 사용량을 모델 구조에서 줄이는 접근을 분석할 수 있음
HW, 시스템	ITME	Disaggregated CXL-Hybrid Memory 기반 메모리 확장	메모리 저장 위치와 계층 확장을 통한 해결 방식을 분석할 수 있음

1.3 비교 범위 및 원칙

- 두 기술의 적용 계층과 전제 조건을 명시한다.
- 성능 수치는 모델, 하드웨어, 문맥 길이, 비교 기준선 등 원문의 실험 조건과 함께 기록한다.
- 서로 다른 실험 환경의 수치를 이용해 직접적인 우열을 결정하지 않는다.
- 기업의 주장, 논문의 실험 결과, 실제 채택 사례를 구분한다.
- 확인되지 않은 정보는 공개 정보 부족으로 표시한다.
- 경쟁 관계와 보안 가능성을 함께 검토하되, 두 기술의 결합 효과를 실증한 것처럼 표현하지 않는다.

2. 시스템, RAG, 임베딩 설계

2.1 SW 기술: DeepSeek-V2의 MLA

DeepSeek-V2의 MLA(Multi-head Latent Attention)는 기존의 Key와 Value를 그대로 저장하는 대신, 저차원 잠재 표현으로 압축하여 KV cache 크기를 줄이는 어텐션 구조이다. 이 기술은 KV cache 자체의 저장량을 줄이는 소프트웨어, 모델 아키텍처 기반 접근으로 분류한다.

- 접근 방식: KV 표현 자체를 저차원 잠재 공간으로 압축
- 기대 효과: GPU HBM 사용량 감소, 장문맥 처리 가능성 확대
- 고려 사항: 모델 구조 차원의 변경이 필요하며, 기존 모델에 즉시 적용하기 어려울 수 있음
- 주요 평가 질문: 메모리 절감 효과가 실제 서비스 적용성, 성능, 생태계 확장성으로 이어지는가?

2.2 HW 기술: ITME

ITME(Inference Tiered Memory Expansion with Disaggregated CXL-Hybrid Memories)는 CXL-Hybrid 메모리를 활용해 LLM 추론 환경의 메모리 계층을 확장하는 접근이다. 이 기술은 KV cache 표현을 직접 줄이기보다, GPU HBM 외부의 계층형 메모리를 활용하여 저장 가능 용량을 확장하는 HW, 시스템 인프라 기반 접근으로 분류한다.

- 접근 방식: CXL 기반 계층형 메모리 확장
- 기대 효과: GPU HBM 용량 한계를 보완하고 대규모 LLM 추론 환경의 확장성 확보
- 고려 사항: 데이터 이동 지연, 신규 인프라 구성, 운영 복잡도 증가 가능성
- 주요 평가 질문: 메모리 확장 효과가 처리량과 비용 개선으로 이어지는가?

2.3 기술 선정 방식

본 프로젝트는 사람이 비교 대상 기술과 평가 기준을 먼저 확정하고, 에이전트가 논문과 외부 자료를 조사한 뒤 사람이 결과를 검토하는 Human-in-the-loop 방식을 적용한다.

기술 선정 단계에서는 다음 기준을 바탕으로 사람이 DeepSeek-V2 MLA와 ITME를 선정한다.

- KV cache 병목을 해결하는 SW와 HW 기술을 각각 하나씩 선정할 것
- 원문 논문 또는 공식 기술 자료를 확보할 수 있을 것
- 기술 원리, 한계, 적용 가능성을 확인할 수 있을 것
- 전체 RAG 대상 문서가 200페이지 이하가 되도록 관리할 수 있을 것
- 데이터센터·클라우드 LLM 서버이라는 동일 도메인에서 비교 가능한 기술일 것

SW 후보 비교

Doc Pool의 SW 후보는 압축,양자화 계열(TurboQuant, KIVI)과 어텐션 아키텍처 개선 계열(DeepSeek-V2)로 나뉜다.

후보	접근	비고
TurboQuant (2025-04)	벡터를 더 적은 비트로 저장하는 범용 온라인 양자화 기법. KV cache에 적용 시 3비트 양자화를 보고	압축,양자화 계열
KIVI (2024-06)	Tuning-free 2비트 양자화. 이미 생성된 KV cache를 사후에 압축하는 양자화 계열의 대표 베이스라인	압축,양자화 계열
DeepSeek-V2 MLA (2024-06)	저차원 잠재 공간으로 KV를 압축하는 어텐션 아키텍처 재설계. 93.3% 감소를 보고	아키텍처 개선 계열 — 최종 선정

TurboQuant와 KIVI는 둘 다 이미 만들어진 KV cache를 사후에 압축하는 방식이라는 점에서 접근 축이 같다. 본 프로젝트는 사후 압축 도구가 아니라 모델 구조 자체에서 KV cache가 작게 나오도록 재설계하는 접근을 비교 대상으로 삼고자 했고, 이 조건을 충족하는 후보는 DeepSeek-V2뿐이었다. 공식 논문과 구현체를 확보할 수 있어 원리,한계 확인도 가능해 DeepSeek-V2의 MLA를 최종 선정하고, 나머지 두 후보는 접근 방식이 이미 선정한 기술과 겹쳐 제외하였다.

HW 후보 비교

Doc Pool의 HW 후보는 동적 KV cache 관리(InfiniGen), CXL 기반 계층 확장(ITME), PIM 기반 확장으로 나뉜다.

후보	접근	비고
InfiniGen (2024-06)	필수 KV 항목만 호스트 메모리로 동적 프리패치, 최대 3배 개선을 보고	동적 KV cache 관리 계열
PIM/CXL 확장 (2025-10)	DIMM 기반 Processing-Near-Memory로 용량과 대역폭을 동시 확장	PIM(연산-메모리 근접) 계열
ITME (2026-06)	CXL-Hybrid Memory를 활용하여 GPU 외부로 KV cache 저장 계층을 확장하고 선제적으로 데이터를 이동하는 시스템. 논문의 실험 환경에서 기존 방식 대비 최대 35.7%의 처리량 향상을 보고	CXL 기반 계층 확장 계열 — 최종 선정

InfiniGen은 저장 공간 자체를 넓히기보다 기존 호스트 메모리로의 오프로딩 시점과 대상을 관리하는 기법에 가까워, "담을 공간을 넓히자"는 HW 진영의 정의와는 접근 축이 다르다고 판단했다. PIM/CXL 확장 논문은 연산을 메모리 근처로 옮기는 방식으로, 저장 계층 자체를 확장하는 것과는 별개의 축이다. ITME는 원본 데이터를 그대로 두고 저장 위치와 계층만 CXL로 확장하는 방식이어서 SW 진영(MLA)과 가장 뚜렷하게 대비되고, 대규모 LLM 추론이라는 이번 프로젝트의 도메인에 직접 보고된 수치도 있어 최종 선정하였다.

선정 이유 종합

DeepSeek-V2 MLA와 ITME는 각각 "저장 데이터를 줄이는 방식"과 "저장 공간을 확장하는 방식"을 대표하므로, KV cache 최적화의 상반된 접근을 비교하기에 적합하다고 판단하였다. 같은 진영의 나머지 후보들도 선정 기준을 상당 부분 충족했지만, KIVI·TurboQuant는 이미 선정한 기술과 접근 축이 겹쳤고 InfiniGen, PIM 확장 논문은 "계층 확장"이라는 HW 진영 정의와 축이 달랐다는 점에서 제외하였다.

단, 두 기술은 개입하는 계층이 다르므로 동일한 실험 환경의 성능 수치를 단순 비교하지 않는다. 대신 처리량, 응답 속도, 정확도 보존, 비용, 운영 복잡도 관점에서 적용 조건과 트레이드오프를 비교한다.

2.4 에이전트 역할

Agent	책임	입력 근거	주요 출력
기술 조사 Agent	원리, 성능, 한계, TRL 분석	논문 RAG	technical_analysis, trl_analysis
시장성 평가 Agent	채택, 생태계, 도입 장벽 조사	외부 웹 검색	market_analysis
이해관계자 평가 Agent	관계자별 기대와 우려 조사	외부 웹 검색	stakeholder_analysis
도메인 평가 Agent	데이터센터, 클라우드 적용성 평가	논문 RAG	domain_analysis
종합 평가 Agent	관점 간 일치, 상충, 보완 가능성 정리	앞 단계 분석 결과	synthesis
보고서 생성 Agent	정해진 목차로 결과 작성	분석, 종합, 검증 결과	report

기술 조사 Agent가 TRL 평가를 함께 담당한다. 별도 TRL Agent를 추가하지 않아 기술 원리와 성숙도 분석의 중복을 줄인다.

이 외에 기술 선정 노드와 규칙 기반 검증 노드를 둔다. 현재 `validation_judge()`는 LLM 평가자가 아닌 Python 검사 함수이다.

2.5 RAG 및 외부 검색 구성

논문 RAG

기술 조사와 도메인 평가에는 원문의 페이지 단위 근거가 필요하므로 논문 RAG를 적용한다.

항목	현재 구현
PDF 확보	지정 URL에서 다운로드, 기존 파일은 재사용
PDF 파싱	PyMuPDF
문서 범위	DeepSeek-V2 52페이지 + ITME 13페이지
페이지 제한	합계 200페이지 초과 시 오류 발생
색인 제외 범위	페이지 본문에서 References 또는 Acknowledgements 제목을 만나면 이후 페이지 제외
칭킹	페이지별 자체 <code>split_text()</code>
칭크 크기	최대 900자
중복 범위	기본 120자
분할 경계	후반부의 줄바꿈, 마침표 경계를 우선 고려
임베딩 실행	Ollama 로컬 실행
임베딩 모델	<code>qwen3-embedding:0.6b</code>
생성 LLM	OpenAI <code>gpt-4o-mini</code>
Vector DB	ChromaDB의 로컬 영속 저장소
Agent 검색 방식	Dense Retrieval, cosine similarity
임베딩 데이터 전송	문서-질의 임베딩은 로컬 처리
생성 데이터 전송	검색된 근거와 Agent 프롬프트는 OpenAI API로 전달
Retriever 평가 방식	상위 10개 후보 검색 후 cosine similarity 85%와 lexical overlap 15%로 재정렬, 최종 Top 5 사용
근거 입력 구성	evidence_id 기준 중복 제거 후 기술별 입력 글자 수 균등 배분
필터	<code>technology</code> 메타데이터로 MLA, ITME 문서 구분
출처 정보	기술명, 파일명, PDF 페이지, URL, 칭크 ID, 검색 점수

칭크 크기의 단위는 문자 수이며, 페이지를 넘는 칭크는 생성하지 않는다. 문서 범위는 사전에 선정한 기술별 논문(SW: DeepSeek-V2 MLA, HW: ITME)으로 한정하며, 검색 대상 문서를 실행 중에 동적으로 추가하지 않는다.

PDF의 전체 페이지 수는 페이지 제한 검사에 사용한다. 실제 색인 생성 시에는 페이지 본문에서 `References` 또는 `Acknowledgements` 제목을 만나면 해당 페이지 이후를 색인하지 않아, 논문 참고문헌이 검색 근거로 사용되는 것을 줄인다.

검색 근거가 한 기술에 편중되지 않도록, LLM에 전달하는 근거는 `evidence_id`를 기준으로 중복을 제거한 후 기술별로 그룹화한다. 전체 입력 글자 수를 기술별로 균등하게 배분하고, 각 기술의 근거를 우선 포함한 뒤 남은 입력 공간에 추가 근거를 포함한다.

현재 lexical rerank는 Retriever 평가 경로에만 적용되어 있다. 평가 시에는 Dense Retrieval로 상위 10개 후보를 검색한 후, cosine similarity 85%와 질문-칭크 간 lexical overlap 15%를 결합하여 재정렬하고 최종 상위 5개를 사용한다.

기술 조사 Agent와 도메인 평가 Agent의 실제 RAG 검색은 cosine similarity 기반 Dense Retrieval 결과를 직접 사용하며 lexical rerank를 적용하지 않는다. Agent 검색 경로에 rerank를 적용하는 것은 후속 개선 항목으로 둔다.

외부 검색

검색 경로는 Tavily를 우선 사용하고, 실패하거나 결과가 없으면 DDGS로, DDGS도 실패하면 DuckDuckGo HTML 검색으로 대체한다.

검색 경로는 다음과 같다.

└ Tavily → 실패하거나 결과가 없으면 DDGS → DDGS 예외 발생 시 DuckDuckGo HTML 검색

검색 결과의 제목, URL, 검색 발췌문 또는 확보한 본문을 근거로 저장한다. 검색 결과 또는 웹페이지 메타데이터에서 발행일을 확인할 수 있으면 `published_at`에 저장하고, 확인할 수 없으면 비워 둔다.

외부 검색 결과는 ChromaDB에 적재하지 않는다. 따라서 본 설계에서 "RAG 적용"은 로컬 논문 검색을 의미하며, 외부 검색은 근거를 제공하는 별도 도구로 구분해 사용한다.

자료 해석 시 다음을 구분한다.

- 해당 기술을 직접 다루는 자료
- MLA 또는 CXL 등 관련 생태계를 다루는 자료
- 기업 홍보 자료
- 독립적인 분석이나 실제 도입 사례

예를 들어 CXL 시장의 성장만으로 ITME의 실제 채택이 확인됐다고 판단하지 않는다.

2.6 임베딩 모델 선정

선정 배경

본 프로젝트의 RAG 파이프라인은 한국어 또는 영어로 입력된 질문을 이용하여 영어로 작성된 DeepSeek-V2 MLA 및 ITME 논문에서 관련 근거를 검색하는 것을 목표로 한다. 임베딩 모델은 기술 조사 Agent와 도메인 평가 Agent의 검색 정확도에 직접적인 영향을 준다. 따라서 공개 Leaderboard 순위만을 따르

지 않고 다음 조건을 함께 고려하였다.

- **공개 모델 여부:** 실습 조건("경제성을 고려한 오픈소스 임베딩 적용")을 충족해야 하며, 유료 API 전용 모델과 가중치 비공개 모델은 제외한다.
- **모델 크기와 경제성:** 팀원의 로컬 제한된 GPU 환경에서 실행할 수 있어야 하며, 문서 임베딩과 질의 처리 비용이 과도하지 않아야 한다.
- **한국어,영어 검색 성능:** 한국어 질문으로 영어 기술 논문의 근거를 검색할 수 있어야 한다.
- **Retrieval 성능:** MTEB 종합 점수가 아니라 RAG 검색과 직접 관련된 Retrieval 점수를 우선한다.
- **구현 안정성과 재현성:** 팀원별 로컬 환경에서 동일한 모델을 Ollama로 실행할 수 있고, 현재 구현된 ChromaDB 기반 Dense Retrieval 파이프라인에 동일한 임베딩 결과와 검색 조건을 재현할 수 있어야 한다.
- **라이선스와 접근성:** 라이선스와 사용 조건이 명확해야 하며, 유료 API, 복잡한 인증, 사용자 정의 코드 의존성을 최소화해야 한다.

1차 필터링: 공개 모델 여부

모델	공개 가중치	판단
google/gemini-embedding-001	X	Google API 전용으로 제외
openai/text-embedding-3-large	X	OpenAI API 전용으로 제외
openai/text-embedding-3-small	X	OpenAI API 전용으로 제외
Qwen-BGE-EmbeddingGemma-GeeVec 계열	O	로컬 실행 후보로 유지

Gemini와 OpenAI 임베딩 모델은 공개 Leaderboard에서 비교 대상으로 참고할 수 있지만, 가중치를 내려받아 로컬에서 실행할 수 없어 최종 후보에서 제외했다.

2차 필터링: 모델 크기와 경제성

그룹	해당 모델	파라미터	Retrieval	판단
초대형	Octen-8B, KaLM-Gemma3-12B, Harrier-27B, Qwen3-8B, Nemotron-8B	약 7.5~27B	71.30~75.36	성능은 높지만 메모리,질의 지연 부담이 커 제외
중형	Qwen3-4B, Jina-v4	약 3.9~4.0B	67.22~70.10	팀원별 로컬 환경에서 동일하게 재현하기 어려워 제외
소형	GeeVec-Lite, EmbeddingGemma-300M, Qwen3-0.6B, BGE-M3	약 0.3~0.6B	53.63~72.80	최종 후보군

본 프로젝트의 RAG 문서는 총 200페이지 이하이므로, 최고 성능 모델보다 팀 전체가 안정적으로 재현할 수 있는 소형 모델이 적합하다고 보았다. 이는 페이지 수가 적으니 소형 모델의 정확도가 충분하다는 뜻이 아니다. 대규모 인프라가 필요하지 않은 작업 규모이므로 자원 부담이 적은 그룹으로 좁혀도 무방하다는 경제성 판단이며, 실제 정확도 적합성은 아래 3차 필터링의 Retrieval 점수 비교로 별도 검증한다.

3차 필터링: 소형 후보 상세 비교

아래 수치는 2026년 6월 MTEB Multilingual(Korean, English), Domain(Web, News, Blog) Retrieval Leaderboard 기준이다.

모델	MTEB 순위	Retrieval	파라미터	임베딩 차원	최대 토큰	Zero-shot	라이선스·접근성
geevect-ai/geevect-embeddings-1.0-lite	8위	72.80	0.349B	최대 4,096	32,768	NA	Apache 2.0, 사용자 정의 코드 필요
google/embeddinggemma-300m	24위	65.17	0.308B	768	2,048	98%	Gemma License, 사용 조건 동의 필요
Qwen/Qwen3-Embedding-0.6B	32위	60.46	0.596B	1,024	32,768	98%	Apache 2.0
BAAI/bge-m3	79위	53.63	0.568B	1,024	8,191	98%	MIT

Qwen3-Embedding-0.6B는 소형 후보 중 Retrieval 점수가 가장 높은 모델은 아니다. 다만 Leaderboard 성능뿐 아니라 라이선스, 접근성, 구현 안정성, 생태계, 교차언어 검색과 팀 단위 재현성을 종합하면 균형이 가장 적절한 모델이다.

최종 선정: Qwen/Qwen3-Embedding-0.6B

본 시스템은 검색 임베딩과 최종 텍스트 생성을 서로 다른 모델로 분리하였다. 문서와 질의 임베딩에는 공개 가중치 모델인 [Qwen3-Embedding-0.6B](#)를 Ollama에서 로컬 실행한다. 이에 따라 임베딩 생성 단계의 문서 청크와 검색 질의는 외부 임베딩 API로 전송되지 않으며, 반복적인 임베딩 API 비용도 발생하지 않는다.

분석 결과의 구조화된 JSON 생성과 최종 한국어 보고서 작성에는 OpenAI [gpt-4o-mini](#)를 사용한다. 이 과정에서 검색된 근거와 Agent 프롬프트가 OpenAI API로 전달될 수 있다. 따라서 본 프로젝트는 오픈소스 임베딩 적용 조건을 충족하지만, 전체 파이프라인이 완전히 로컬에서 실행되거나 모든 원문 정보가 외부로 전송되지 않는 구조는 아니다.

BGE-M3와의 정량 비교:

비교 기준	Qwen3-Embedding-0.6B	BGE-M3	판단
MTEB 순위	32위	79위	Qwen 우세
Multilingual Retrieval	60.46	53.63	Qwen +6.83점(약 12.73% 우세)
파라미터	0.596B	0.568B	Qwen이 약 4.93% 큼
임베딩 차원	1,024	1,024	동일 → 벡터 저장 비용 동일
최대 입력 토큰	32,768	8,191	Qwen 약 4배(본 프로젝트는 약 900자 단위 청킹이라 결정적 이유는 아님)

비교 기준	Qwen3-Embedding-0.6B	BGE-M3	판단
라이선스	Apache 2.0	MIT	모두 사용 가능
Sparse-Multi-vector	미지원	지원	BGE 우세(현재 구조는 Dense Retrieval만 사용하므로 미활용)

선정 이유:

- BGE-M3보다 파라미터가 약 4.93%만 증가하지만 Retrieval 점수는 6.83점 높아, 비슷한 실행,저장 비용으로 더 높은 다국어 검색 성능을 기대할 수 있다.
- 100개 이상의 언어를 지원해 한국어 질문과 영어 논문을 동일한 임베딩 공간에서 비교할 수 있다.
- Apache 2.0 라이선스로 사용,수정,재배포 조건이 명확하고, 유료 임베딩 API 비용이 들지 않는다.
- EmbeddingGemma와 달리 gated 모델 사용 조건 동의가 필요 없고, GeeVec-Lite와 달리 사용자 정의 원격 코드 실행을 전제로 하지 않는다.
- 검색 임베딩은 `qwen3-embedding:0.6b` 를 Ollama에서 로컬 실행하고, Agent의 구조화된 JSON 분석과 최종 보고서 생성은 OpenAI `gpt-4o-mini` 가 담당한다. 따라서 임베딩 단계는 팀원별로 동일하게 재현할 수 있지만, Agent의 텍스트 생성 단계에는 OpenAI API가 필요하다.

다른 모델을 선택하지 않은 이유

- GeeVec-Embeddings-1.0-Lite:**
Retrieval 72.80으로 소형 후보 중 최고 점수이며 라이선스도 Apache 2.0으로 명확하다. 다만 MTEB 표의 Zero-shot 정보가 NA이고, 공개 이력이 짧아 독립 검증 사례가 적다. `trust_remote_code=True` 기반의 사용자 정의 코드 실행이 필요해 재현 위험도 있다. 성능 비교용 도전자 모델로는 유지하되 기본 모델에서는 제외했다.
- EmbeddingGemma-300M:**
Retrieval 65.17로 Qwen보다 4.71점 높고 파라미터도 약 48% 작다. 그러나 Hugging Face 사용 조건에 동의해야 하는 gated 모델이고 Gemma License가 적용된다. 팀원별 계정,인증 상태에 따라 다운로드 과정이 달라질 수 있어, 검색 성능보다 팀 단위 접근성과 라이선스 재현성을 우선해 제외했다.
- BGE-M3:**
가장 오래 검증되었고 Dense-Sparse,Multi-vector를 모두 지원한다. 현재 구조는 Ollama와 ChromaDB를 이용한 Dense Retrieval만 구현했으므로, BGE-M3가 제공하는 Sparse Retrieval과 Multi-vector Retrieval 기능을 활용하지 않는다.
- Qwen3-Embedding-4B / 8B:**
Retrieval 점수는 각각 +9.64점, +12.30점 높지만 파라미터가 0.6B 대비 약 6.75배, 12.70배 늘어난다. 200페이지 이하의 문서 풀 규모를 고려하면 추가 성능 대비 로컬 실행 비용과 팀 단위 재현성 부담이 더 크다고 보아 제외했다.

에이전트별 영향

에이전트	RAG 적용	임베딩 모델의 영향
기술 조사 Agent	O	MLA-ITME 원리, 성능, 한계, TRL 근거 검색에 직접 영향
도메인 평가 Agent	O	HBM-CXL-처리량-지연시간-비용 근거 검색에 직접 영향
시장성 평가 Agent	X	직접 영향 없음(외부 웹 검색)
이해관계자 평가 Agent	X	직접 영향 없음(외부 웹 검색)
종합 평가 Agent	X	앞 단계 검색 근거 품질을 통한 간접 영향
보고서 생성 Agent	X	근거 전달 정확도를 통한 간접 영향

자체 검증 계획 및 현재 구현 범위

현재 `evaluate.py`에는 DeepSeek-V2 MLA 5개, ITME 5개로 구성된 총 10개의 영어 평가 질문이 정의되어 있다. 각 질문에는 팀원이 원문을 확인하여 지정한 정답 청크 ID가 2개씩 등록되어 있다.

평가에서는 기술별 메타데이터 필터를 적용한 후 Dense Retrieval로 상위 10개 후보를 검색하고, cosine similarity 85%와 lexical overlap 15%를 결합하여 재정렬한 상위 5개를 사용한다. 현재 구현된 지표는 Hit@5와 MRR이며, 질문별 정답 순위, 일치한 청크 ID, 검색된 청크 ID도 함께 출력한다.

현재 평가 질문은 모두 영어이므로 영어 질문 → 영어 논문 검색을 평가한다. 한국어 → 영어 교차언어 검색 성능, 질의 지연시간, 메모리 사용량은 아직 평가 코드에 구현되어 있지 않다. 따라서 이 항목들은 완료된 검증 결과가 아니라 후속 검증 계획으로 둔다.

추후에는 기존 영어 질문과 의미가 동일한 한국어 질문 세트를 추가하여 언어별 Hit@5와 MRR을 비교한다. 다중 관련도 정답을 이용하는 Recall 또는 nDCG는 계산 방식을 구현하고 정답 관련도 등급을 확정한 이후에 사용한다.

3. 평가 관점 및 기준

3.1 공통 출력 기준

각 평가 결과에는 다음 내용을 포함한다.

- 평가 대상 기술
- 평가 항목
- 확인된 사실
- reference내 근거 ID 출처
- 실험 또는 적용 조건

- 해석과 한계
- 공개 정보가 부족한 부분

자료에 실제로 나타난 반응과 Agent의 해석을 구분한다.

3.2 기술 성숙도: TRL

기술 조사 Agent가 다음 기준으로 공개 정보 기반 TRL을 추정한다.

단계	판단 기준	공개 정보의 양
TRL 1	기초 원리 관찰	대부분 공개
TRL 2	기술 개념과 적용 가능성 정립	• 논문, 학회 발표, 특허 출원이 해당 구간의 주된 결과물 • 기업이 적극적으로 공개하는 구간
TRL 3	핵심 기능의 개념 검증	• 연구 방향을 알려 인재 채용, 투자 유치, 표준화 주도권 확보에 유리하기 때문
TRL 4	실험실에서 구성요소 검증	GAP이 가장 크게 발생
TRL 5	관련 환경에서 구성요소 검증	
TRL 6	관련 환경에서 시스템 프로토타입 시연	• 수율, 공정 파라미터, 실제 성능 수치가 핵심 영업 비밀
TRL 7	실제 운용 환경에서 프로토타입 시연	일부 공개
TRL 8	완성된 시스템의 검증	• 고객사 샘플 공급, 양산 발표, 실적 공시 등 비즈니스 목적으로 공개
TRL 9	실제 운용 실적 확인	• 단 구체적인 수율과 원가는 여전히 비공개

이런 공개 정보 비대칭 때문에 다음 원칙을 따른다.

- 논문 발표만으로 특정 단계를 자동 부여하지 않는다. 코드 공개, 프로토타입, 실험 환경, 시스템 통합, 실제 운용 근거를 함께 확인한다.
- MLA와 ITME 각각의 평가 대상과 범위를 명시하고, 관련 기업이나 주변 기술의 성숙도를 해당 기술의 TRL로 대신하지 않는다.
- 실제 상용 운용 단계의 근거가 부족하면 추정을 유보하거나 범위와 한계를 표시한다.
- KV cache 기술은 논문 발표 시점과 실제 채택 간 시차가 있으므로, 공개 정보 기반 추정임을 반드시 명시한다.

3.3 시장성

평가 범위는 데이터센터, 클라우드 LLM 추론 인프라 시장이다.

평가 항목	확인할 근거
시장 규모·성장성	시장 리포트, 산업 뉴스 등에 나타난 관련 시장 규모와 성장 추이
수요	장문맥, 동시 요청, 메모리 비용 문제와의 관련성
채택	해당 기술의 실제 적용, 통합 사례, 제품 출시 발표
생태계	서빙 프레임워크, 모델, 하드웨어 지원, 표준화 동향
도입 장벽	모델 변경, 추가 장비, 기존 시스템 호환성
경제성	공개된 비용 근거와 추가 투자 요구

전체 AI 시장 규모를 개별 기술의 시장 규모처럼 사용하지 않는다. 공개된 비용 자료가 없으면 임의의 절감률을 생성하지 않는다.

DeepSeek-V3와 같은 후속 모델이 MLA를 사용한다는 사실은 MLA 생태계의 간접 근거로 활용할 수 있지만, DeepSeek-V2 MLA 자체의 상용화 또는 시장 채택 사례로 동일시하지 않는다. CXL 관련 시장 성장이나 제품 출시 역시 ITME 시스템 자체의 채택 근거와 구분한다.

3.4 이해관계자

이해관계자	평가 초점
클라우드 사업자	처리량, 서비스 비용 및 확장성
LLM 개발사	모델 구조 및 품질, 개발 부담
서비스 개발자	서빙 호환성, 구현 난이도
GPU·메모리 업체	하드웨어 요구, 생태계 영향
도입 기업·운영자	추가 투자 및 운영 복잡도, 안정성

각 관계자의 기대효과와 우려를 함께 기록한다. 직접적인 발언이나 도입 사례를 찾지 못하면 직접 반응 근거 없음으로 표시한다.

직접 반응 근거 없음은 분석 문장에 기록하며, `evidence_ids` 배열에는 넣지 않는다. 근거가 없더라도 Agent가 예상한 반응을 실제 이해관계자의 반응처럼 표현하지 않는다.

3.5 도메인 적용성

데이터센터, 클라우드 LLM 서빙 도메인을 선택한 이유는 GPU HBM 부족이라는 문제가 직접 발생하는 환경이며, 처리량·응답 속도, 정확도, 비용을 두 기술에 공통으로 적용 가능한 평가 기준으로 사용할 수 있기 때문이다. OnDevice AI(자원 제약, 전력 민감)나 장문맥 처리 어플리케이션(문맥 길이 민감)도 후보로 고려했으나, 두 기술이 공통으로 겪는 GPU 메모리 병목이 가장 직접적으로 나타나는 환경은 데이터센터·클라우드 서빙이라고 판단해 이 도메인을 선택했다.

공통 평가 항목은 다음과 같다.

- HBM 사용량
- 장문맥 확장성
- 동시 사용자 수용 능력
- 첫 토큰 응답 시간
- 처리량
- 정확도 영향
- 데이터 전송 지연
- 신규 인프라 요구
- 서버 시스템 호환성
- 운영 복잡도와 비용

각 수치에는 비교 기준선과 실험 조건을 붙인다. 직접 비교가 어려우면 조건 차이 자체를 평가 결과로 남긴다.

DeepSeek-V2 논문의 KV cache 93.3% 감소는 DeepSeek 67B와 비교한 KV cache 저장량 결과이므로 이를 전체 HBM 사용량이 93.3% 감소한 것으로 확대 해석하지 않는다. 최대 생성 처리량은 기준 대비 5.76배 또는 기준의 576%로 표현하며, 576% 향상 과 혼동하지 않는다.

4. State 및 Graph 설계

4.1 State Schema

다음 표는 실제 AgentState 선언과 대응한다.

State Key	타입	작성 주체	내용
input_request	str	실행 진입점	평가 요청
selected_technologies	dict	기술 선정 노드	사람이 선택한 기술
selection_reason	str	기술 선정 노드	선정 이유
domain	str	기술 선정 노드	평가 도메인
technical_analysis	dict	기술 조사 Agent	원리, 성능, 한계
trl_analysis	dict	기술 조사 Agent	TRL 추정과 근거
market_analysis	dict	시장성 평가 Agent	시장, 채택, 생태계 분석
stakeholder_analysis	dict	이해관계자 평가 Agent	관계자별 평가
domain_analysis	dict	도메인 평가 Agent	공통 도메인 기준 평가
synthesis	dict	총합 평가 Agent	일치, 상충, 보완 가능성
validation_result	str	검증 노드	pass, retry, pass_with_limitations
missing_evidence	list[str]	검증 노드	누락, 오류 항목
retry_targets	list[str]	검증 노드	실패한 역할 목록
retry_count	int	기술 선정-검증 노드	재조사 횟수
report	str	보고서 생성 Agent	Markdown 보고서
references	list[dict]	각 평가 Agent	검색 근거 목록
errors	list[str]	각 노드	실행 오류
runtime_metadata	dict	파이프라인 실행 종료 후	Python·운영체제·모델·실행 모드·칭킹 설정

PDF, 청크, ChromaDB 객체는 현재 Graph 외부에서 준비한다. 실제 State에 없는 vectorstore, source_documents 등을 구현된 State 키로 기재하지 않는다.

4.2 병렬 결과 병합

각 Agent는 담당 분석 키를 반환한다. 공유 목록은 다음 reducer로 병합한다.

- references: merge_references() 가 동일 논문 청크 또는 동일 웹 URL을 병합
- errors: 목록을 누적

논문 근거 ID는 기술명과 청크 ID를 이용하여 생성하며, 동일 기술의 동일 청크가 여러 질의나 Agent에서 검색되더라도 같은 evidence_id를 사용한다. 웹 근거 ID는 URL을 기준으로 생성하므로 동일 URL은 같은 ID를 사용한다.

merge_references()는 논문 근거를 기술명과 청크 ID 기준으로, 웹 근거를 URL 기준으로 병합한다. 최종 REFERENCE 생성 단계에서는 논문은 논문 URL 또는 파일명 기준, 웹 자료는 URL 기준으로 다시 중복을 제거한다.


4.3 근거 Schema

필드	의미
evidence_id	근거 식별자
agent, technology	수집 주체와 대상 기술
source_type	논문 또는 웹
title, url, file_name	자료 식별 정보
page, chunk_id	논문 원문 위치
evidence_text	확보한 근거 내용
retrieval_score	검색 점수
published_at	웹 검색 결과 또는 웹페이지 메타데이터에서 확인한 발행일
claim	현재 코드에서는 검색 질의 저장

`published_at`은 Tavily-DDGS가 제공한 날짜 또는 웹페이지의 메타데이터와 JSON-LD에서 확인한 날짜를 저장한다. 날짜를 확인할 수 없으면 비워 두며 임의로 생성하지 않는다.

`claim`은 검증된 주장 자체가 아니라 해당 근거를 찾을 때 사용한 검색 질의이므로 해석에 주의한다.

4.4 Graph 흐름



```

flowchart TD
    START([시작]) --> TS[technology_selection]
    TS --> TR[technical_research]

    TR --> ME[market_evaluation]
    TR --> SE[stakeholder_evaluation]
    TR --> DE[domain_evaluation]

    ME --> SYN[synthesis]
    SE --> SYN
    DE --> SYN

    SYN --> VAL[validation]
    VAL -. retry .-> TR
    VAL -. "pass 또는 pass_with_limitations" .-> RG[report_generation]
    RG --> END([종료])
  
```

종합 평가 Agent는 세 병렬 평가가 모두 완료된 이후 실행되도록 설계한다. `retry_targets`는 실패한 역할을 기록하는 용도이며, 실제 자동 재시도는 기술 조사부터 평가 단계를 다시 실행하고 특정 Agent만 선택적으로 재실행하지는 않는다.

Graph가 종료된 후 `app.py`의 `save_outputs()`가 보고서 구조를 검사하고 Markdown, HTML, PDF, State JSON을 저장한다.

4.5 실행 모드

설정	빠른 확인 모드	최종 실행 모드
FAST_MODE	True	False
자동 재시도	0회	최대 2회
Agent 검색 개수	질의당 2개	질의당 5개
웹 결과 수	질의당 1개	질의당 4개
RAG 질의	통합 질의로 축소	기준별 질의
외부 본문 확보	생략	가능한 경로에서 시도

현재 `config.py`의 기본 설정은 `FAST_MODE=true`인 빠른 확인 모드이다.

빠른 확인 모드는 Graph 연결과 Agent 실행 여부를 점검하는 용도이며, 제출용 보고서는 환경변수 `FAST_MODE=false`로 생성한다.

최종 실행 완료 조건은 다음과 같다.

- `validation_result = pass`
- `missing_evidence = []`
- `errors = []`
- `FAST_MODE = False`

4.6 검증 범위

현재 보고서 생성 전 `validation_judge()`가 검사하는 항목은 다음과 같다.

- 필수 분석 결과의 존재 여부
- 빈 하위 분석 또는 JSON 파싱 오류 여부
- `evidence_id` 형식의 유효성
- 참조된 `evidence_id`가 State의 `references`에 등록되어 있는지
- Reference 근거 목록 존재 여부

검사 결과에 따라 다음 상태를 사용한다.

- `pass`: 검사 항목에서 누락을 발견하지 않음
- `retry`: 재조사가 가능한 누락이 있고 재시도 횟수가 남아 있음
- `pass_with_limitations`: 누락이 있으나 재시도 대상이 아니거나 재시도 횟수를 모두 사용함

`pass_with_limitations`도 현재 Graph에서는 보고서 생성 단계로 이동한다. 따라서 해당 상태로 생성된 보고서는 한계 내용을 사람이 확인해야 하며, 최종 제출 완료 상태로 보지 않는다.

최종 보고서 본문에는 가독성을 위해 내부 `evidence_id`를 표시하지 않는다. 근거 연결 관계는 각 Agent의 구조화된 분석 결과와 State JSON에 유지한다. 보고서 생성 단계에서는 기술 조사, TRL, 시장성, 이해관계자, 도메인 및 종합 평가 결과의 `evidence_ids`를 수집하여 최종 REFERENCE를 구성한다.

보고서 생성 후 `validate_report()`는 다음 항목을 검사한다.

- SUMMARY, 분석 배경, 기술 선정, 기술 개요, 관점별 평가, 시사점, 분석의 한계, REFERENCE 제목 존재 여부
- REFERENCE가 SUMMARY보다 뒤에 있는지
- REFERENCE가 마지막 최상위 제목인지
- REFERENCE가 비어 있지 않은지
- 보고서에 표시된 근거 ID가 있는 경우 해당 ID가 State의 `references`에 존재하는지

현재 최종 보고서 본문에서는 내부 근거 ID를 제거하므로, 근거의 유효성 검사는 주로 보고서 생성 전의 구조화된 Agent 분석 결과를 대상으로 수행한다.

현재 `validation_judge()`와 `validate_report()`는 다음 내용을 자동으로 검사하지 않는다.

- 내부 Agent 분석의 근거가 해당 주장을 의미적으로 뒷받침하는지
- 전체 분석에서 사용한 자료가 최종 REFERENCE에 빠짐없이 포함됐는지
- REFERENCE가 과제의 저자·기관·발행일 형식을 완전히 충족하는지
- DeepSeek-V2와 DeepSeek-V3 등 기술명이 혼입됐는지
- TRL, 시장성, 이해관계자 평가가 근거보다 과장됐는지
- 제5장 [관점별 비교 및 상충 지점](#)이 존재하는지
- 각 절이 목표 분량을 실제로 충족하는지
- 보고서 본문에서 사실, 해석, 판단의 한계가 적절히 구분됐는지

따라서 최종 제출 전에는 다음 항목을 사람이 추가로 확인한다.

- 수치, 성능, TRL, 채택, 비용 주장이 내부 Agent 분석의 `evidence_ids`와 연결되어 있는지
- 연결된 원문이 해당 주장을 실제로 뒷받침하는지

- 내부 분석에서 사용한 DeepSeek-V2 및 ITME 원 논문이 최종 REFERENCE에 포함됐는지
- 두 기술의 근거가 모두 포함됐는지
- 검색 결과가 해당 기술을 직접 다루는지
- TRL 판단에 단계별 근거가 있는지
- 생성 보고서에 잘못된 기술명·수치·무근거 결론이 없는지
- KV cache 93.3% 감소가 전체 HBM 사용량 감소로 확대 해석되지 않았는지
- 기존 대비 5.76배 처리량이 576% 향상으로 잘못 표현되지 않았는지
- 근거가 없는 이해관계자 반응을 실제 반응처럼 표현하지 않았는지
- 두 기술의 결합 가능성을 검증된 성능 향상처럼 표현하지 않았는지
- 특정 기술을 최종 승자로 추천하거나 우열을 단정하지 않았는지

5.2 REFERENCE 생성 방식

현재 참고문헌 생성 함수는 논문과 웹 자료를 구분하여 출력한다.

- 논문은 config.py에 등록된 저자, 연도, 논문 제목, arXiv ID와 검색 페이지를 사용한다.
- 웹 자료는 URL 도메인, 확인된 발행일, 자료 제목과 URL을 사용한다.
- 논문 자료는 논문 URL 또는 파일명 기준으로 중복을 제거한다.
- 웹 자료는 URL 기준으로 중복을 제거한다.

보고서 생성 단계에서는 기술 조사, TRL, 시장성, 이해관계자, 도메인 및 종합 평가 결과에 포함된 전체 evidence_ids를 수집한다. 최종 보고서 본문에서는 가독성을 위해 내부 근거 ID를 제거하지만, 수집된 ID에 해당하는 자료는 REFERENCE에 유지한다.

따라서 논문 근거는 본문에 evidence_id가 직접 표시되지 않더라도, 기술 조사·TRL·도메인 분석 등 내부 분석 결과의 evidence_ids에 정상적으로 포함되어 있으면 최종 REFERENCE에 포함된다. 시장성·이해관계자 분석에서 사용한 웹 근거도 동일한 방식으로 REFERENCE 대상에 포함된다.

근거 추적 관계는 다음과 같이 관리한다.

원문 또는 웹 자료 → Evidence 객체 → Agent 분석의 evidence_ids → State JSON → 최종 REFERENCE

최종 보고서 본문은 읽기 편한 평가 문서로 제공하고, 세부 근거 ID와 Agent별 근거 연결 관계는 State JSON에서 확인할 수 있도록 분리한다.

현재 웹 자료의 작성자나 기관명을 직접 식별하지 못하면 URL 도메인을 사이트명으로 사용한다. 따라서 자동 생성된 REFERENCE가 과제에서 요구하는 저자·기관·발행일 표기 형식을 완전히 충족하는지는 최종 제출 전에 원문과 대조하여 보완한다.

최종 제출 전에는 다음 내용을 확인한다.

- 내부 분석에서 사용한 모든 자료가 REFERENCE에 포함됐는지
- DeepSeek-V2와 ITME 원 논문이 포함됐는지
- 동일 자료가 중복으로 기재되지 않았는지
- 웹 자료의 작성자 또는 기관명과 발행일이 정확한지
- 본문에서 활용하지 않은 자료가 불필요하게 포함되지 않았는지

6. 참고자료

- DeepSeek-AI(2024). DeepSeek-V2: A Strong, Economical, and Efficient Mixture-of-Experts Language Model. *arXiv*, 2405.04434. <https://arxiv.org/abs/2405.04434>
- Jang, H. et al.(2026). ITME: Inference Tiered Memory Expansion with Disaggregated CXL-Hybrid Memories. *arXiv*, 2606.12556. <https://arxiv.org/abs/2606.12556>
- Qwen. Qwen3-Embedding-0.6B Model Card. Hugging Face. <https://huggingface.co/Qwen/Qwen3-Embedding-0.6B>
- BAAI. BGE-M3 Model Card. Hugging Face. <https://huggingface.co/BAAI/bge-m3>
- MTEB. MTEB Leaderboard: Multilingual(Korean, English), Domain(Web, News, Blog), 2026-06 기준.