

SUMMARY

본 보고서는 데이터센터에서 LLM 서빙 시 발생하는 KV cache 문제를 해결하기 위한 두 가지 기술, Multi-head Latent Attention(MLA) 기반의 DeepSeek-V2와 Inference Tiered Memory Expansion(ITME)을 비교합니다. 두 기술은 서로 다른 계층에서 KV cache 병목을 해결하는 접근 방식을 가지고 있으며, 각각의 장점과 제약이 존재합니다. DeepSeek-V2는 긴 문맥 처리와 효율적인 메모리 사용에 강점을 보이며, ITME는 하드웨어 기반의 메모리 확장을 통해 성능을 향상시킵니다. 그러나 두 기술 모두 특정 조건에서 성능 저하가 발생할 수 있는 한계를 가지고 있습니다. 추가적인 검증 과제가 필요하며, 각 기술의 적용 조건에 따라 최적의 선택이 달라질 수 있습니다. 이 보고서는 각 기술의 TRL, 시장성, 이해관계자의 기대와 우려를 종합적으로 분석하여, 향후 연구 및 개발 방향을 제시합니다.

1. 분석 배경

데이터센터에서 LLM 서빙 시 KV cache는 메모리 사용량과 긴 컨텍스트 처리, 동시 사용자 수와 밀접한 관계가 있습니다. KV cache는 모델의 성능을 좌우하는 중요한 요소로, 메모리 용량이 부족하거나 긴 문맥을 처리할 때 성능 저하가 발생할 수 있습니다. 이러한 문제는 데이터센터의 운영 효율성에 직접적인 영향을 미치며, 따라서 KV cache의 최적화는 필수적입니다. 본 보고서는 이러한 문제를 해결하기 위해 MLA와 ITME 두 가지 기술을 비교하며, 각 기술의 장단점을 평가합니다. 이 비교는 KV cache의 효율성을 높이고, 데이터센터의 운영 비용을 절감하는 데 기여할 수 있는 방향으로 진행됩니다. 특히, 두 기술의 접근 방식이 서로 다르기 때문에, 이들의 비교는 단순한 성능 평가를 넘어 데이터센터 운영의 전반적인 전략 수립에 중요한 통찰을 제공할 것입니다. 이러한 분석을 통해 데이터센터 운영자들은 보다 효과적인 기술 선택을 할 수 있을 것으로 기대됩니다.

2. 기술 선정

MLA와 ITME는 KV cache 병목 문제를 해결하기 위해 서로 다른 계층에서 접근합니다. MLA는 소프트웨어 계층에서 모델 구조를 최적화하여 KV cache의 크기를 줄이는 반면, ITME는 하드웨어 및 메모리 계층에서 메모리 확장을 통해 성능을 향상시킵니다. 이러한 접근 방식의 차이는 두 기술의 비교 가능성을 높이며, 각 기술이 제공하는 해결책의 차별성을 명확히 합니다. 그러나 두

기술의 성능 비교는 실험 환경의 차이로 인해 직접적인 수치 비교가 어려울 수 있습니다. 예를 들어, MLA는 소프트웨어 최적화에 중점을 두고 있어 특정 하드웨어 환경에서 최적의 성능을 발휘할 수 있지만, ITME는 하드웨어 의존성이 크기 때문에 다양한 환경에서의 성능 변동이 클 수 있습니다. 이러한 점에서 두 기술의 성능 비교는 단순한 수치적 접근을 넘어, 각 기술의 적용 조건과 환경을 고려해야 함을 시사합니다.

3. 기술 개요

3.1 DeepSeek-V2 MLA

DeepSeek-V2는 Multi-head Latent Attention(MLA) 메커니즘을 기반으로 하여, 키-값 캐시의 크기를 줄이고 효율적인 추론을 가능하게 하는 저랭크 키-값 조합 압축을 사용합니다. 이 기술은 128K의 긴 문맥 길이를 지원하며, 다양한 자연어 처리 작업에서 우수한 성능을 입증하였습니다. DeepSeek-V2는 Dense DeepSeek 67B 모델에 비해 42.5%의 훈련 비용 절감을 달성했으며, MMLU, ARC, BBH 등에서 높은 정확도를 기록했습니다. 그러나 MLA는 균형 잡힌 로드 분배를 목표로 하지만, 엄격한 로드 균형을 보장할 수 없으며, 특정 장치의 통신 효율성에 영향을 받을 수 있습니다. 이러한 한계는 DeepSeek-V2의 성능이 특정 환경에서 최적화될 수 있지만, 모든 환경에서 동일한 성능을 보장하지는 않는다는 점에서 주의가 필요합니다. 따라서 DeepSeek-V2의 적용은 특정 사용 사례와 환경에 따라 달라질 수 있습니다.

3.2 ITME

ITME는 CXL-hybrid 메모리를 활용하여 대규모 바이트 주소 가능 원격 메모리 확장을 제공하는 아키텍처입니다. 이 시스템은 데이터 이동을 메모리-스토리지 계층 간에 능동적으로 관리하여 메모리 용량 및 I/O 병목 현상을 완화합니다. ITME는 CPU 오프로드를 제공하여 다양한 모델 크기에서 확장성을 입증하며, FPGA 프로토타입 구현에서 평균 18 GB/s의 읽기 속도와 12 GB/s의 쓰기 속도를 달성했습니다. 그러나 FPGA 구현의 대역폭은 캐시 미스 시 1 GB/s 이하로 감소할 수 있으며, 극심한 경쟁 상황에서 성능 변동이 발생할 수 있습니다. 이러한 점은 ITME의 성능이 특정 환경에서 최적화될 수 있지만, 모든 환경에서 동일한 성능을 보장하지는 않는다는 점에서 주의가 필요합니다. 따라서 ITME의 적용은 특정 사용 사례와 환경에 따라 달라질 수 있습니다.

4. 관점별 평가

4.1 기술 성숙도 및 TRL

DeepSeek-V2는 실제 서비스에 배포되어 운영되고 있으며, 다양한 벤치마크에서 성능을 입증하였습니다. 따라서 TRL 8로 추정됩니다. ITME는 FPGA 기반 프로토타입을 통해 하드웨어의 실행 가능성을 입증하였으나, 실제 운영 환경에서의 사용 근거는 부족하여 TRL 6으로 추정됩니다. 이러한 TRL 추정은 각 기술의 현재 상태를 반영하지만, 향후 기술 발전이나 시장 변화에 따라 달라질 수 있습니다.

4.2 시장성

DeepSeek-V2는 Mixture-of-Experts(MoE) 아키텍처와 MLA 기술을 통해 효율적인 훈련과 추론을 제공하며, 이는 시장에서의 수요를 증가시키고 있습니다. 특히, DeepSeek-V2와 V3는 오픈소스 모델로 제공되어 연구자와 개발자들 사이에서 빠르게 채택되고 있습니다. 그러나

DeepSeek-V3의 상용화에는 하드웨어 요구 사항이 크고, 공식 API 사용 시 데이터 주권 위험이 존재하여 기업의 도입 장벽이 될 수 있습니다. ITME는 CXL 메모리 풀을 통해 LLM 추론에서 KV 캐시 압력을 완화하고, GPU VRAM을 보완하여 성능을 향상시키는 데 기여하고 있습니다. 그러나 CXL 메모리의 도입에는 기존 인프라와의 호환성 문제와 추가적인 기술적 요구 사항이 존재하여 도입 장벽이 될 수 있습니다. 이러한 시장 환경은 기술의 채택과 확산에 중요한 영향을 미치며, 기업들은 이러한 요소를 고려하여 기술 도입 전략을 수립해야 합니다.

4.3 이해관계자

클라우드 사업자는 DeepSeek-V2를 통해 비용 효율적인 클라우드 서비스 제공 및 높은 처리량을 통한 고객 만족도를 기대하지만, 모델의 비효율성이나 예기치 않은 비용 발생 가능성에 대한 우려가 있습니다. LLM 개발자는 혁신적인 아키텍처를 통한 모델 성능 향상 및 비용 절감을 기대하지만, 모델의 한계와 비사실적 정보 생성 가능성에 대한 우려가 있습니다. 서비스 개발자는 빠른 배포와 저렴한 비용으로 서비스 개발 가능성을 기대하지만, 모델의 언어적 한계와 비사실적 정보 생성에 대한 우려가 있습니다. 하드웨어 업체는 AI 하드웨어 생태계의 성장과 새로운 시장 기회 창출을 기대하지만, 기술 혁신에 대한 적시 대응의 어려움이 우려됩니다. 이러한 다양한 이해관계자들의 기대와 우려는 기술 선택 및 운영 전략에 중요한 영향을 미치며, 각 이해관계자는 자신의 요구와 환경에 맞는 최적의 기술을 선택해야 합니다.

4.4 데이터센터·클라우드 적용성

DeepSeek-V2는 128K 토큰까지 지원하여 긴 문맥 처리 가능성을 제공하며, 메모리 사용량을 효율적으로 줄일 수 있습니다. 그러나 모델 크기에 따라 메모리 요구량이 증가할 수 있습니다.

ITME는 CXL-하이브리드 메모리를 활용하여 메모리 용량을 확장할 수 있지만, 복잡한 메모리 관리가 필요합니다. 두 기술 모두 높은 동시 사용자 처리 가능성을 제공하지만, 서버 자원에 따라 제한될 수 있습니다. 또한, 처리량과 정확도 유지에 대한 기대효과가 있지만, 메모리 관리에 따른 성능 저하 가능성도 존재합니다. 이러한 요소들은 데이터센터 운영의 효율성을 높이는 데 중요한 역할을 하며, 각 기술의 적용 조건에 따라 최적의 선택이 달라질 수 있습니다.

5. 관점별 비교 및 상충 지점

DeepSeek-V2와 ITME는 서로 다른 아키텍처와 접근 방식을 가지고 있어 직접적인 경쟁 관계에 있습니다. DeepSeek-V2는 소프트웨어 기반의 접근 방식을 취하는 반면, ITME는 하드웨어 기반의 접근 방식을 가지고 있습니다. 두 기술 모두 효율적인 메모리 사용과 비용 절감을 목표로 하고 있지만, 운영 환경에서의 성능 저하 가능성은 각 기술의 한계로 작용할 수 있습니다. 따라서 직접적인 우열 판단은 위험할 수 있으며, 각 기술의 적용 조건에 따라 최적의 선택이 달라질 수 있습니다. 이러한 점은 데이터센터 운영자들이 기술 선택 시 고려해야 할 중요한 요소입니다.

6. 시사점

기술 선택은 특정 서빙 조건에 따라 달라질 수 있으며, 각 기술의 검증 질문을 우선적으로 고려해야 합니다. DeepSeek-V2는 긴 문맥 처리와 메모리 효율성을 중시하는 환경에서 유리할 수 있으며, ITME는 하드웨어 확장을 통해 성능을 극대화할 수 있는 환경에서 적합할 수 있습니다. PoC 및 벤치마크 후속 과제를 통해 각 기술의 실제 성능을 검증하고, 최적의 운영 조건을 찾아야 합니다. 이러한 과정은 데이터센터 운영의 효율성을 높이는 데 기여할 수 있으며, 각 기술의 장단점을 명확히 이해하는 것이 중요합니다.

7. 분석의 한계

본 보고서는 논문 및 웹 자료를 기반으로 작성되었으며, 검색 품질과 실험 조건의 불일치로 인해 일부 정보의 신뢰성이 제한적일 수 있습니다. 또한, 공개되지 않은 비용, 운영 및 상용화 정보에 대

한 부족함이 있으며, LLM 생성 해석의 한계로 인해 기술의 실제 적용 가능성에 대한 평가가 제한적일 수 있습니다. 이러한 한계는 기술 선택 및 운영 전략 수립 시 주의해야 할 요소로 작용할 수 있으며, 향후 추가적인 연구와 검증이 필요합니다.

REFERENCE

- [rag-58c91483dc1b] DeepSeek-AI(2024). DeepSeek-V2: A Strong, Economical, and Efficient Mixture-of-Experts Language Model. arXiv:2405.04434. (p.11)
- [rag-f0779c824898] Jang, H., Min, Y., Kim, S., Ahn, T., Kim, H., Joo, Y., Kim, H., & Kim, J.(2026). ITME: Inference Tiered Memory Expansion with Disaggregated CXL-Hybrid Memories. arXiv:2606.12556. (p.11)
- [web-79bf6b4435bc] arxiv.org(날짜 미상). DeepSeek-V3 Technical Report - arXiv, <https://arxiv.org/html/2412.19437v1>
- [web-041fd7f90e07] huggingface.co(날짜 미상). deepseek-ai/DeepSeek-V2-Lite · Hugging Face, <https://huggingface.co/deepseek-ai/DeepSeek-V2-Lite>
- [web-bbefe1ddb166] www.turingpost.com(2024-08-28). Inside DeepSeek Models: MoE, MLA, and Coder-V2 ..., <https://www.turingpost.com/p/deepseek>
- [web-e1900c38df6b] cryptorank.io(2025-01-29). Meet Luo Fuli: The AI pro behind DeepSeek's open-source model and MLA technology | AI OpenAI | CryptoRank.io, <https://cryptorank.io/news/feed/29815-meet-luo-fuli-ai-expert-behind-deepseek-mla>
- [web-1d8e8063adfc] inferenceops.substack.com(2025-10-09). State of the Model Serving Communities - October 2025, <https://inferenceops.substack.com/p/state-of-the-model-serving-communities-269>
- [web-708e063d9704] www.spheron.network(2026-06-25). Multi-Head Latent Attention (MLA) on GPU Cloud: Cut KV ..., <https://www.spheron.network/blog/multi-head-latent-attention-mla-gpu-cloud>
- [web-18e6669f5ce9] arxiv.org(날짜 미상). Enabling DeepSeek's Multi-Head Latent Attention in Any ..., <https://arxiv.org/html/2502.14837v1>
- [web-966c08505acc] www.gmicloud.ai(2026-05-22). Where to Deploy DeepSeek-V3 for Production AI Inference, <https://www.gmicloud.ai/en/blog/where-to-deploy-deepseek-v3-for-production-ai-inference>
- [web-a1e440b91c17] www.chipstrat.com(2025-02-24). DeepSeek MoE and V2 - by Austin Lyons, <https://www.chipstrat.com/p/deepseek-moe-and-v2>

- [web-367c9a10a5c3] [www.leoniscap.com](https://www.leoniscap.com/research/deepseek-a-technical-and-strategic-analysis-for-vcs-and-startups)(날짜 미상). DeepSeek: A Technical and Strategic Analysis for VCs and ..., <https://www.leoniscap.com/research/deepseek-a-technical-and-strategic-analysis-for-vcs-and-startups>
- [web-30df5b70cbee] [www.ceramic.ai](https://www.ceramic.ai/blog/re-deepseek)(날짜 미상). Cost and Efficiency of DeepSeek, <https://www.ceramic.ai/blog/re-deepseek>
- [web-1c9c23bccb6a] [newsletter.semianalysis.com](https://newsletter.semianalysis.com/p/deepseek-debates)(2025-01-31). DeepSeek Debates: Chinese Leadership On Cost, True Training ..., <https://newsletter.semianalysis.com/p/deepseek-debates>
- [web-da6e58e6a279] [arxiv.org](https://arxiv.org/html/2606.12556v2)(날짜 미상). ITME: Inference Tiered Memory Expansion with ..., <https://arxiv.org/html/2606.12556v2>
- [web-687f2444f44a] [www.alphaxiv.org](https://www.alphaxiv.org/abs/2606.12556)(날짜 미상). ITME: Inference Tiered Memory Expansion with ..., <https://www.alphaxiv.org/abs/2606.12556>
- [web-0d0561365c5d] [www.semanticscholar.org](https://www.semanticscholar.org/paper/ITME%3A-Inference-Tiered-Memory-Expansion-with-Jang-Min/935228feb1a5d966c6ece0532bf6e0136d614f7f)(날짜 미상). ITME: Inference Tiered Memory Expansion with Disaggregated CXL ..., <https://www.semanticscholar.org/paper/ITME%3A-Inference-Tiered-Memory-Expansion-with-Jang-Min/935228feb1a5d966c6ece0532bf6e0136d614f7f>
- [web-9d3c2fa530c8] [pure.kaist.ac.kr](https://pure.kaist.ac.kr/en/publications/a-simulator-for-llm-inference-systems-exploiting-cxl-memory-pools)(날짜 미상). A Simulator for LLM Inference Systems Exploiting CXL ..., <https://pure.kaist.ac.kr/en/publications/a-simulator-for-llm-inference-systems-exploiting-cxl-memory-pools>
- [web-e39af51d02fd] [www.youtube.com](https://www.youtube.com/watch?v=krB97KQerm8)(날짜 미상). Accelerating LLM Serving with Prompt Cache Offloading via CXL, <https://www.youtube.com/watch?v=krB97KQerm8>
- [web-e3bd12f4be55] [acecloud.ai](https://acecloud.ai/blog/cxl-memory-llm-inference)(2026-08-25). CXL Memory For LLM Inference: Breaking The AI ..., <https://acecloud.ai/blog/cxl-memory-llm-inference>
- [web-8296cb80093e] [finance.yahoo.com](https://finance.yahoo.com/news/wolley-introduces-cxl-memory-expansion-130000438.html)(2025-08-06). Wolley Introduces CXL® Memory Expansion Controller for AI Workstation at FMS2025, <https://finance.yahoo.com/news/wolley-introduces-cxl-memory-expansion-130000438.html>
- [web-0511b7e559e8] [computeexpresslink.org](https://computeexpresslink.org/blog/overcoming-the-ai-memory-wall-how-cxl-memory-pooling-powers-the-next-leap-in-scalable-ai-computing-4267)(2025-11-14). Overcoming the AI Memory Wall: How CXL ..., <https://computeexpresslink.org/blog/overcoming-the-ai-memory-wall-how-cxl-memory-pooling-powers-the-next-leap-in-scalable-ai-computing-4267>
- [web-472a3e49b78c] [arxiv.org](https://arxiv.org/html/2606.12556v1)(날짜 미상). ITME: Inference Tiered Memory Expansion with Disaggregated CXL ..., <https://arxiv.org/html/2606.12556v1>

- [web-03fe77ddc58d] [www.fortunebusinessinsights.com](https://www.fortunebusinessinsights.com/cxl-memory-pooling-appliance-market-117960)(날짜 미상). CXL Memory Pooling Appliance Market Size, Share [2026- ..., <https://www.fortunebusinessinsights.com/cxl-memory-pooling-appliance-market-117960>
- [web-f6d969472719] [dataintel.com](https://dataintel.com/report/cxl-memory-pooling-software-market)(2025-09-30). CXL Memory Pooling Software Market, <https://dataintel.com/report/cxl-memory-pooling-software-market>
- [web-411304b8dfef] [finance.yahoo.com](https://finance.yahoo.com/news/montage-technology-introduces-cxl-3-150000451.html)(2025-09-01). Montage Technology Introduces CXL® 3.1 Memory eXpander Controller to Empower Next-Generation Data Center Infrastructure, <https://finance.yahoo.com/news/montage-technology-introduces-cxl-3-150000451.html>
- [web-5175a77604cd] [arxiv.org](https://arxiv.org/pdf/2405.04434)(날짜 미상). DeepSeek-V2, <https://arxiv.org/pdf/2405.04434>
- [web-3b58dce57d02] [medium.com](https://medium.com/data-science-collective/understanding-deepseek-v2-my-personal-take-3182794898ce)(2025-04-24). Understanding DeepSeek v2: My Personal Take - Medium, <https://medium.com/data-science-collective/understanding-deepseek-v2-my-personal-take-3182794898ce>
- [web-acabf4ee155d] [discuss.huggingface.co](https://discuss.huggingface.co/t/multi-latent-attention-mla-implementation-from-deepseek-v2/139924)(2025-02-10). Multi-Latent Attention (MLA) Implementation from ..., <https://discuss.huggingface.co/t/multi-latent-attention-mla-implementation-from-deepseek-v2/139924>
- [web-3ea8781cc686] [www.spheron.network](https://www.spheron.network/blog/deploy-deepseek-r2-gpu-cloud)(2026-04-05). Deploy DeepSeek R2 on GPU Cloud: Self-Host the Best ..., <https://www.spheron.network/blog/deploy-deepseek-r2-gpu-cloud>
- [web-8eb12065b934] [api-docs.deepseek.com](https://api-docs.deepseek.com/quick_start/pricing)(날짜 미상). Models & Pricing - DeepSeek API Docs, https://api-docs.deepseek.com/quick_start/pricing
- [web-107ee275566d] [www.alibabacloud.com](https://www.alibabacloud.com/en/solutions/tech-solution/deepseek-r1-for-platforms?_p_lc=1)(날짜 미상). Fast Deployment of All-Size DeepSeek Models, https://www.alibabacloud.com/en/solutions/tech-solution/deepseek-r1-for-platforms?_p_lc=1
- [web-ea6fc0b40882] [www.kucoin.com](https://www.kucoin.com/news/flash/deepseek-s-strategy-building-a-10-trillion-ai-hardware-ecosystem)(날짜 미상). DeepSeek's Strategy: Building a \$10 Trillion AI Hardware ..., <https://www.kucoin.com/news/flash/deepseek-s-strategy-building-a-10-trillion-ai-hardware-ecosystem>
- [web-d5d0ae6e64c7] [finance.yahoo.com](https://finance.yahoo.com/news/deepseek-china-moves-nvidias-cuda-093000950.html)(2025-02-12). With DeepSeek, China moves to take on Nvidia's CUDA ecosystem, <https://finance.yahoo.com/news/deepseek-china-moves-nvidias-cuda-093000950.html>
- [web-f23a5c6aa837] [www.oracle.com](https://www.oracle.com/cloud/cloud-computing-cost)(2024-01-25). Cloud Computing Costs in 2024, <https://www.oracle.com/cloud/cloud-computing-cost>