

SUMMARY

본 보고서는 DeepSeek-V2와 ITME 기술의 비교를 통해 데이터센터 LLM 서빙에서의 KV cache 문제를 해결하기 위한 두 가지 접근 방식을 분석합니다. DeepSeek-V2는 Multi-head Latent Attention(MLA) 메커니즘을 활용하여 키-값 캐시의 저차원 압축을 통해 효율적인 추론을 가능하게 하며, ITME는 CXL-hybrid 메모리를 통해 대규모 메모리 확장을 제공합니다. 두 기술 모두 긴 컨텍스트 처리와 동시 사용자 수 증가에 강점을 보이지만, 각각의 기술적 제약과 운영 복잡성이 존재합니다. DeepSeek-V2는 훈련 비용을 42.5% 절감할 수 있는 가능성을 보여주며, ITME는 최대 35.7%의 처리량 향상을 달성할 수 있습니다. 그러나 ITME의 실제 운영 환경에서의 사용 근거는 부족하여 신뢰성에 대한 의문이 제기될 수 있습니다. 두 기술은 서로 다른 요구 사항을 충족할 수 있어 보완적인 관계를 형성할 수 있습니다. 추가 검증이 필요하며, PoC 및 벤치마크 후속 과제가 요구됩니다.

1. 분석 배경

데이터센터에서 LLM 서빙 시 KV cache는 메모리 사용량과 긴 컨텍스트 처리, 동시 사용자 수와 밀접한 관계가 있습니다. KV cache는 모델의 성능을 좌우하는 중요한 요소로, 메모리 용량이 부족할 경우 성능 저하가 발생할 수 있습니다. 본 보고서는 DeepSeek-V2와 ITME라는 두 가지 기술을 비교하여 KV cache 문제를 해결하기 위한 접근 방식을 평가합니다. 이 두 기술은 서로 다른 계층에서 문제를 해결하고 있으며, 각각의 장점과 제약을 분석하여 데이터센터 운영에 미치는 영향을 평가합니다. 그러나 현재까지의 공개 정보는 제한적이며, 두 기술의 실제 적용 사례나 성능 검증에 대한 자료가 부족하여 신뢰성에 대한 의문이 제기될 수 있습니다. 따라서, 추가적인 연구와 검증이 필요합니다. [공개 정보 부족]

평가의 출발점은 KV cache를 단순한 메모리 절감 문제가 아니라 모델 구조, 메모리 계층, 입력 길이와 동시성에 함께 영향을 받는 시스템 문제로 보는 것이다. 따라서 공개 자료의 기술 설명과 실험 수치를 실제 데이터센터 성능으로 바로 일반화하지 않고, 측정 조건과 적용 범위를 함께 기록해야 한다.

본 보고서는 기술 성숙도, 시장성, 이해관계자 요구, 도메인 적용성의 네 관점으로 두 접근을 검토한다. 이 범위는 기술 원리만 확인하는 데서 끝나지 않고 도입 장벽과 운영 검증 과제까지 구분하기 위한 것이다.

2. 기술 선정

DeepSeek-V2와 ITME는 KV cache 병목 문제를 해결하기 위해 서로 다른 소프트웨어 및 하드웨어 계층에서 접근하고 있습니다.

DeepSeek-V2는 MLA 메커니즘을 통해 소프트웨어적으로 키-값 캐시를 압축하여 효율적인 추론을 가능하게 하며, ITME는 CXL-hybrid 메모리를 활용하여 하드웨어적으로 메모리 용량을 확장합니다. 이러한 접근 방식의 차이는 두 기술의 비교 가능성을 높이며, 각각의 기술이 해결하고자 하는 문제의 본질을 이해하는 데 도움을 줍니다. 그러나 두 기술의 성능을 직접 비교하는 데는 한계가 있으며, 각 기술의 실험 환경과 조건이 다르기 때문에 신중한 해석이 필요합니다. 특히, DeepSeek-V2의 성능은 훈련 데이터의 품질에 의존하며, ITME는 하드웨어 환경에 따라 성능 변동이 클 수 있습니다. 이러한 점에서 두 기술의 비교는 단순한 수치적 비교를 넘어, 각 기술의 특성과 적용 환경을 고려해야 합니다. [공개 정보 부족]

두 기술을 함께 선택한 이유는 동일한 KV cache 병목을 모델 내부와 메모리 시스템이라는 서로 다른 계층에서 다루기 때문이다. 이 차이는 비교의 범위를 넓혀 주지만, 실험 조건과 평가 단위가 다르므로 수치의 직접 대조에는 주의가 필요하다.

따라서 비교 결과는 우열 판정이 아니라 각 기술이 어떤 병목과 요구사항에 대응하는지, 그리고 어떤 추가 실험이 필요한지를 설명하는 데 사용한다.

3. 기술 개요

3.1 DeepSeek-V2 MLA

DeepSeek-V2는 MLA 메커니즘을 기반으로 하여 키-값 캐시의 저차원 압축을 통해 효율적인 추론을 가능하게 합니다. 이 시스템은 긴 문맥을 처리하는 데 최적화되어 있으며, 다양한 자연어 처리 작업에서 성능을 발휘합니다. DeepSeek-V2는 128K의 긴 문맥 길이에서도 우수한 성능을 보이며, Dense DeepSeek 67B 모델에 비해 42.5%의 훈련 비용 절감 효과를 보여줍니다. 그러나 MLA 메커니즘은 특정 상황에서 완벽한 부하 균형을 보장하지 않으며, 성능은 훈련 데이터의 품질에 의존합니다. 이러한 특성은 DeepSeek-V2의 활용 가능성을 높이는 동시에, 특정 환경에서는 성능 저하를 초래할 수 있는 위험 요소로 작용할 수 있습니다. 따라서, DeepSeek-V2의 실제 적용에 있어서는 훈

런 데이터의 품질 관리와 함께, 다양한 환경에서의 성능 검증이 필요합니다. [rag-b55138902476], [rag-17cd949afb16], [rag-58c91483dc1b], [rag-6b0fb1b202ba]

3.2 ITME

ITME는 CXL-hybrid 메모리를 활용하여 대규모 바이트 주소 가능 원격 메모리 확장을 제공하는 아키텍처입니다. 이 시스템은 KV cache와 모델 데이터의 배치 또는 이동 방식을 최적화하여 메모리 용량과 I/O 병목 현상을 완화하는 데 중점을 두고 있습니다. ITME는 CPU 오프로드 기준에 비해 최대 35.7%의 처리량 향상을 달성하며, FPGA 프로토타입 구현에서 평균 18 GB/s의 읽기 속도와 12 GB/s의 쓰기 속도를 기록했습니다. 그러나 현재 FPGA 구현의 대역폭은 캐시 미스 발생 시 1 GB/s 이하로 저하될 수 있으며, 극심한 경쟁 상황에서 성능 변동이 발생할 수 있습니다. 이러한 점은 ITME의 실제 운영 환경에서의 신뢰성을 저해할 수 있는 요소로 작용할 수 있으며, 따라서 ITME의 상용화에 있어서는 추가적인 검증과 안정성 확보가 필요합니다. [rag-2151c100ee42], [rag-56d88cbf22fa], [rag-0d449b4c0c09], [rag-569adb3e3b18]

4. 관점별 평가

4.1 기술 성숙도 및 TRL

DeepSeek-V2는 실제 서비스에 배포되어 운영되고 있으며, 다양한 벤치마크에서 성능을 검증받았습니다. 따라서 TRL은 8로 추정됩니다. ITME는 FPGA 기반 프로토타입을 통해 하드웨어 제어 논리를 검증하고 소프트웨어 프리패칭의 효과를 평가했으나, 실제 운영 환경에서의 사용 근거는 부족하여 TRL은 6으로 추정됩니다. 이러한 TRL 추정치는 공개된 정보에 기반한 것으로, 실제 운영 환경에서의 성능 검증이 이루어질 경우 TRL이 변화할 수 있습니다. [rag-b55138902476], [rag-17cd949afb16], [rag-56d88cbf22fa], [rag-0d449b4c0c09]

4.2 시장성

DeepSeek-V2는 혁신적인 아키텍처를 통해 경제적인 훈련과 효율적인 추론을 보장하며, AI 모델의 수요 증가에 기여하고 있습니다. Mixture-of-Experts(MoE) 아키텍처와 MLA 메커니즘을 통해 빠른 정보 처리와 메모리 사용량 감소를 실현하여 채택이 증가하고 있습니다. 그러나 기술적 복잡성과 초기 투자 비용이 높은 점은 도입 장벽으로 작용할 수 있습니다. ITME는 CXL 메모리를 통해 AI 인프라의 메모리 요구를 충족시키기 위해 점점 더 많은 수요를 받고 있으며, 고속 GPU HBM을 보완하여 메모리 용량을 확장하는 데 도움을 주고 있습니다. 그러나 CXL 솔루션은 전용 메모리 모듈과 인프라 구성 요소가 필요하여 초기 비용이 높아 도입 장벽이 존재합니다. 이러한 시장 환경에서 두 기술의 경쟁력은 각 기술의 특성과 시장 요구에 따라 달라질 수 있으며, 따라서 지속적인 시장 모니터링과 기술 발전이 필요합니다. [web-2e4ae681b7e4], [web-79eb55ac7258], [web-bbefe1ddb166], [web-e3bd12f4be55], [web-13cacb360cb1]

4.3 이해관계자

클라우드 사업자는 DeepSeek-V2를 통해 비용 효율적인 클라우드 서비스를 제공할 수 있으나, 복잡한 구현과 최적화 필요성에 대한 우려가 있습니다. LLM 개발자는 효율적인 모델 개발 및 성능 향상을 기대하지만, 기술적 전문성 부족으로 인한 도입 장벽이 존재합니다. 서비스 개발자는 빠른 응답 시간과 낮은 계산 비용을 기대하지만, 기술적 용어의 복잡성으로 인해 이해 부족이 우려됩니다. 하드웨어 업체는 ITME를 통해 로컬 하드웨어에 대한 수요 증가를 기대하지만, 기존 생태계와의 통합 문제를 우려하고 있습니다. 운영자는 비용 절감 및 성능 향상을 기대하지만, 보안 및 개인 정보 문제에 대한 우려가 있습니다. 이러한 다양한 이해관계자들의 요구와 우려를 반영하여, 두 기술의 개발과 상용화 과정에서의 소통과 협력이 중요합니다. [web-46c6e6190519], [web-5175a77604cd], [web-107ee275566d], [web-d5d0ae6e64c7], [web-fffde3bed35a]

4.4 데이터센터·클라우드 적응성

DeepSeek-V2는 효율적인 메모리 사용으로 훈련 비용을 절감할 수 있으며, 최대 128K 토큰의 긴 컨텍스트를 지원합니다. 그러나 모델 크기에 따라 메모리 요구 사항이 증가할 수 있습니다. ITME는 CXL-하이브리드 메모리를 활용하여 메모리 용량을 확장할 수 있으며, 긴 컨텍스트 데이터의 예측 가능성을 활용하여 성능 향상을 기대할 수 있습니다. 그러나 하드웨어 및 소프트웨어 최적화가 필요합니다. 두 기술 모두 높은 동시 사용자 처리 능력을 보이며, DeepSeek-V2는 높은 처리량을 자랑하고, ITME는 TTFT 속도를 개선하기 위해 CPU 오프로드 및 프리패칭을 사용합니다. 이러한 특성들은 데이터센터의 운영 효율성을 높이는 데 기여할 수 있지만, 각 기술의 적용 환경에 따라 성능 차이가 발생할 수 있음을 유의해야 합니다. [rag-0ab43e592500], [rag-5bfa0716dd11], [rag-3c0c767ebf6d]

5. 관점별 비교 및 상충 지점

DeepSeek-V2와 ITME는 서로 다른 아키텍처와 최적화 전략을 가지고 있어 직접적인 경쟁 관계에 있습니다. DeepSeek-V2는 소프트웨어 중심의 최적화를 강조하는 반면, ITME는 하드웨어 중심의 메모리 확장을 강조합니다. 두 기술의 성능을 직접 비교하는 것은 실험 단위와 시스템 계층 차이로 인해 위험할 수 있으며, 각 기술의 적용 조건에 따라 성능 차이가 발생할 수 있습니다. 이러한 점에서 두 기술의 비교는 단순한 수치적 비교를 넘어, 각 기술의 특성과 적용 환경을 고려해야 합니다. [rag-6b0fb1b202ba], [rag-58c91483dc1b, rag-3c0c767ebf6d]

두 기술의 비교는 동일한 목표를 서로 다른 계층에서 다루는지부터 구분해야 한다. DeepSeek-V2 MLA는 모델의 어텐션과 KV 표현 방식을 바꾸는 접근이고, ITME는 HBM과 확장 메모리 사이의 배치·이동 경로를 다루는 접근이다. 따라서 메모리 사용량, 긴 컨텍스트, 동시 요청 처리, 데이터 이동 지연, 구현 복잡도는 비교 가능한 항목이지만 동일한 실험 조건에서 측정되지 않았다면 수치를 바로 대조할 수 없다. 한 기술의 논문 수치가 다른 기술보다 크거나 작다는 사실만으로 전체적인 우열을 판단하는 것도 적절하지 않다. 각 결과가 어떤 모델, 하드웨어, 입력 길이, 동시성, 소프트웨어 버전에서 측정됐는지를 함께 확인해야 한다.

두 접근은 경쟁 관계로만 볼 필요도 없다. 모델 내부의 KV 표현을 줄이는 방식과 외부 메모리 계층을 확장하는 방식은 동일한 시스템에서 서로 다른 병목을 완화할 가능성이 있지만, 실제 결합 가능성은 구현 호환성과 데이터 이동 비용을 별도로 검증해야 한다. 비교의 핵심은 전체적인 우열을 정하는 것이 아니라 어떤 조건에서 어떤 병목이 남는지 확인하는 데 있다. 후속 검증에서는 동일한 모델과 입력 집합을 사용해 HBM 사용량, TTFT, 처리량, tail latency, 정확도, 메모리 이동량을 같은 측정 절차로 기록해야 한다. 그 결과가 확보되기 전까지는 공개 자료가 보여주는 장점과 실제 운영 효과를 구분해 해석해야 한다.

6. 시사점

기술 선택은 특정 서빙 조건에 따라 달라질 수 있으며, 각 기술의 검증 질문을 우선적으로 고려해야 합니다. DeepSeek-V2는 긴 컨텍스트 처리와 동시 사용자 수 증가에 강점을 보이는 반면, ITME는 메모리 용량 확장에 중점을 두고 있습니다. PoC 및 벤치마크 후속 과제를 통해 각 기술의 성능을 검증하고, 실제 운영 환경에서의 적용 가능성을 평가해야 합니다. 이러한 과정은 각 기술의 신뢰성을 높이고, 데이터센터 운영의 효율성을 극대화하는 데 기여할 것입니다. [공개 정보 부족]

이 분석의 시사점은 두 기술 중 하나를 선택하는 결론이 아니라, 적용 조건에 따라 무엇을 먼저 검증해야 하는지를 정리하는 데 있다. MLA 처럼 모델 내부의 KV 표현과 저장량을 바꾸는 접근은 모델 구조, 어텐션 구현, 긴 컨텍스트 길이, 동시 요청 수를 함께 확인해야 한다. ITME 처럼 메모리 계층과 데이터 이동 경로를 바꾸는 접근은 HBM과 CXL 사이의 이동량, 접근 지연, 대역폭, 버퍼 관리, 장치 호환성을 별도로 확인해야 한다. 따라서 공개 자료에서 확인된 원리나 프로토타입 결과를 실제 서비스의 처리량과 비용으로 바로 일반화해서는 안 된다. 두 접근을 검토할 때에는 먼저 동일한 모델, 하드웨어, 소프트웨어 버전, 입력 길이, 동시성 조건을 고정한 기준선을 마련해야 한다. 그 다음 KV cache 사용량, HBM 점유량, 첫 토큰 지연시간, 토큰 처리량, tail latency, 데이터 이동량, 정확도 변화를 같은 방식으로 측정해야 한다. 결과가 확인되더라도 운영 복잡도와 장애 대응 방식, 기존 서빙 스택과의 호환성, 추가 장비 및 개발 비용을 함께 기록해야 한다. 이런 절차를 거쳐야만 기술의 장점과 제약을 동일한 판단 단위에서 비교할 수 있다.

후속 PoC에서는 기술별로 확인 가능한 주장과 아직 공개 정보가 부족한 주장을 분리해 실험 계획에 반영해야 한다. 예를 들어 짧은 입력과 긴 입력, 낮은 동시성과 높은 동시성, 캐시 적중과 캐시 교체가 많은 상황을 나누어 측정하면 특정 조건에만 나타나는 효과를 구분할 수 있다. 또한 단일 평균값만 기록하지 말고 반복 측정의 분산과 최악 구간을 함께 기록해야 한다. 모델 정확도나 응답 품질이 유지되는지도 같은 질의 집합으로 확인해야 하며, 메모리 절감이 실제 비용 절감으로 이어지는지는 인프라 가격과 운영 정책을 포함해 별도로 계산해야 한다. 현재 자료만으로는 이 후속 결과를 확정할 수 없으므로, 본 보고서의 시사점은 의사결정의 방향이 아니라 검증 우선순위와 측정 항목을 제안하는 수준으로 해석해야 한다.

7. 분석의 한계

본 보고서에서 사용된 논문 및 웹 자료의 범위는 제한적이며, 검색 품질에 따라 정보의 신뢰성이 달라질 수 있습니다. 실험 조건의 불일치로 인해 두 기술의 성능 비교에 한계가 있으며, 공개되지 않은 비용, 운영 및 상용화 정보가 부족하여 판단에 영향을 미칠 수 있습니다. 또한, LLM 생성 해석의 한계로 인해 기술의 실제 성능을 예측하는 데 어려움이 있을 수 있습니다. 이러한 한계는 향후 연구에서 해결해야 할 중요한 과제로 남아 있습니다. [공개 정보 부족]

본 분석의 한계는 근거가 없다는 사실과 기술이 존재하지 않는다는 판단을 구분해야 한다는 점에서 시작한다. 현재 보고서는 제공된 논문과 검색된 공개 자료를 바탕으로 작성되었으며, 모든 구현 버전, 내부 운영 지표, 계약 조건, 실제 구매 비용과 상용 서비스의 세부 설정을 확인한 것은 아니다. 논문마다 모델 크기, 하드웨어, 입력 길이, 동시성, 측정 방법이 다를 수 있으므로 서로 다른 실험의 수치를 직접 비교

하면 해석이 왜곡될 수 있다. 웹 자료는 게시 시점과 검색 결과의 품질에 영향을 받으며, 자료가 갱신되거나 접근이 제한될 가능성도 있다. 또한 검색된 자료에 특정 관점의 정보가 더 많이 포함되면 시장성이나 이해관계자 분석이 실제보다 풍부하게 보일 수 있다. 이 보고서의 문장은 입력된 근거를 요약하고 연결한 결과이므로, 원문이 말하지 않은 운영 효과나 도입 가능성을 사실처럼 확정하지 않아야 한다. 등록되지 않은 근거 ID가 붙은 주장은 제외했으며, 이는 해당 주장이 거짓이라는 뜻이 아니라 현재 자료로 완전히 추적할 수 없다는 뜻이다.

따라서 최종 판단 전에 원문 페이지와 웹 출처를 사람이 다시 대조하고, 동일 조건의 재현 실험을 수행해야 한다. 재현 실험에는 모델과 라이브러리 버전, 하드웨어 구성, 입력 분포, 동시 요청 수, warm-up 방식, 캐시 정책, 측정 구간을 명시해야 한다. 공개 자료에서 확인되지 않는 비용과 운영 난이도는 공급자 자료나 PoC 로그로 보완해야 하며, 단일 실험 결과를 일반적인 우열 판단으로 확대하지 않아야 한다. 추가 자료가 확보되면 기존 결론을 그대로 유지하기보다 주장별 근거 연결과 조건을 다시 점검해야 한다. 이 한계 때문에 본 보고서는 기술 선택을 확정하는 문서가 아니라, 공개 근거를 기준으로 비교 가능한 항목과 추가 검증이 필요한 항목을 구분한 사전 평가로 보는 것이 적절하다.

REFERENCE

- [rag-58c91483dc1b] [rag-b55138902476] [rag-17cd949afb16] [rag-6b0fb1b202ba] [rag-0ab43e592500] [rag-5bfa0716dd11] DeepSeek-AI(2024). DeepSeek-V2: A Strong, Economical, and Efficient Mixture-of-Experts Language Model. arXiv:2405.04434. (pp.1, 4, 11, 16, 19)
- [rag-569adb3e3b18] [rag-2151c100ee42] [rag-0d449b4c0c09] [rag-56d88cbf22fa] [rag-3c0c767ebf6d] Jang, H., Min, Y., Kim, S., Ahn, T., Kim, H., Joo, Y., Kim, H., & Kim, J.(2026). ITME: Inference Tiered Memory Expansion with Disaggregated CXL-Hybrid Memories. arXiv:2606.12556. (pp.1, 10, 11)
- [web-2e4ae681b7e4] ollama.com(날짜 미상). mannix/deepseek-v2-lite-instruct, <https://ollama.com/mannix/deepseek-v2-lite-instruct>
- [web-79eb55ac7258] arxiv.org(날짜 미상). [2405.04434] DeepSeek-V2: A Strong, Economical, and Efficient Mixture-of-Experts Language Model, <https://arxiv.org/abs/2405.04434>
- [web-bbefe1ddb166] www.turingpost.com(2024-08-28). Inside DeepSeek Models: MoE, MLA, and Coder-V2 Explained, <https://www.turingpost.com/p/deepseek>
- [web-e3bd12f4be55] acecloud.ai(2026-08-25). CXL Memory For LLM Inference: Breaking The AI Memory Wall, <https://acecloud.ai/blog/cxl-memory-llm-inference>
- [web-13cacb360cb1] www.datamintelligence.com(2026-09-28). CXL Memory Market Size, Share & Forecast 2035, <https://www.datamintelligence.com/research-report/cxl-memory-market>
- [web-5175a77604cd] arxiv.org(날짜 미상). DeepSeek-V2, <https://arxiv.org/pdf/2405.04434>
- [web-107ee275566d] www.alibabacloud.com(날짜 미상). Fast and Low-cost Deployment of DeepSeek Models of All Sizes Without Complex Coding - Alibaba Cloud, https://www.alibabacloud.com/en/solutions/tech-solution/deepseek-r1-for-platforms?p_lc=1
- [web-d5d0ae6e64c7] finance.yahoo.com(2025-02-12). With DeepSeek, China moves to take on Nvidia's CUDA ecosystem, <https://finance.yahoo.com/news/deepseek-china-moves-nvidias-cuda-093000950.html>
- [web-46c6e6190519] ultraaiguide.com(2026-03-23). DeepSeek MLA Explained: Complete Beginner to Advanced Guide, <https://ultraaiguide.com/deepseek-mla-explained-guide>
- [web-fffde3bed35a] www.digitalocean.com(날짜 미상). The Pros and Cons of DeepSeek | DigitalOcean, <https://www.digitalocean.com/resources/articles/deepseek-pros-and-cons>