

SUMMARY

본 보고서는 DeepSeek-V2와 ITME 기술의 비교를 통해 데이터센터 LLM 서빙에서의 KV 캐시 문제를 해결하기 위한 두 가지 접근 방식을 분석하였다. DeepSeek-V2는 Multi-head Latent Attention(MLA)을 통해 KV 캐시의 필요량을 줄이며, ITME는 CXL-hybrid 메모리를 활용하여 메모리 확장을 지원한다. 두 기술 모두 긴 컨텍스트와 동시 사용자 처리에서 장점을 보이나, 각각의 기술적 제약이 존재한다. DeepSeek-V2는 공개 배포와 실제 운영 실적을 통해 TRL 8로 평가되며, ITME는 FPGA 프로토타입을 기반으로 TRL 6으로 추정된다. 시장에서는 두 기술 모두 메모리 집약적인 AI 작업에 대한 수요 증가가 예상되지만, 독립적인 출처에서의 검증이 부족하여 확정적인 결론을 내리기 어렵다. 또한, 두 기술의 도입 장벽과 운영 비용에 대한 정보가 부족하여 추가 검증이 필요하다.

1. 분석 배경

데이터센터에서 LLM 서빙 시 KV 캐시는 메모리 사용의 비효율성을 초래할 수 있으며, 이는 긴 컨텍스트와 동시 사용자 수에 따라 더욱 심화된다. 긴 컨텍스트를 처리하기 위해서는 더 많은 메모리가 필요하고, 동시에 여러 사용자의 요청을 처리하기 위해서는 높은 처리량이 요구된다. 이러한 문제를 해결하기 위해 본 보고서는 DeepSeek-V2와 ITME라는 두 가지 기술을 비교하여 평가할 것이다. 이 두 기술은 서로 다른 계층에서 KV 캐시 문제를 해결하는 접근 방식을 가지고 있으며, 각각의 장점과 제약을 분석할 예정이다.

평가의 출발점은 KV cache를 단순한 메모리 절감 문제가 아니라 모델 구조, 메모리 계층, 입력 길이와 동시성에 함께 영향을 받는 시스템 문제로 보는 것이다. 따라서 공개 자료의 기술 설명과 실험 수치를 실제 데이터센터 성능으로 바로 일반화하지 않고, 측정 조건과 적용 범위를 함께 기록해야 한다.

본 보고서는 기술 성숙도, 시장성, 이해관계자 요구, 도메인 적용성의 네 관점으로 두 접근을 검토한다. 이 범위는 기술 원리만 확인하는 데서 끝나지 않고 도입 장벽과 운영 검증 과제까지 구분하기 위한 것이다.

2. 기술 선정

DeepSeek-V2와 ITME는 동일한 KV 캐시 병목 문제를 해결하기 위해 서로 다른 계층에서 접근하고 있다. DeepSeek-V2는 소프트웨어 계층에서 MLA를 통해 KV 캐시를 줄이는 혁신적인 방법을 제시하며, ITME는 하드웨어 및 메모리 계층에서 CXL-hybrid 메모리를 활용하여 메모리 확장을 지원한다. 이러한 접근 방식의 차이는 두 기술의 비교 가능성을 높이며, 서로의 강점을 보완할 수 있는 가능성을 제시한다. 그러나 두 기술의 실험 환경이 다르기 때문에 직접 비교에는 한계가 있다.

두 기술을 함께 선정한 이유는 동일한 KV cache 병목을 모델 내부와 메모리 시스템이라는 서로 다른 계층에서 다루기 때문이다. 이 차이는 비교의 범위를 넓혀 주지만, 실험 조건과 평가 단위가 다르므로 수치의 직접 대조에는 주의가 필요하다.

따라서 비교 결과는 우열 판정이 아니라 각 기술이 어떤 병목과 요구사항에 대응하는지, 그리고 어떤 추가 실험이 필요한지를 설명하는 데 사용한다.

3. 기술 개요

3.1 DeepSeek-V2 MLA

DeepSeek-V2의 Multi-head Latent Attention(MLA)은 저차원 키-값(KV) 공동 압축을 통해 KV 캐시의 크기를 크게 줄입니다. MLA는 키와 값을 압축된 잠재 벡터로 결합하여, 추론 시 필요한 KV 캐시의 양을 현저히 감소시킵니다. 이 방식은 기존의 다중 헤드 주의(MHA)보다 더 나은 성능을 제공하면서도 필요한 KV 캐시의 양을 크게 줄이는 혁신적인 접근입니다. [1]

MLA는 decoupled RoPE 전략을 통해 행렬 흡수 문제를 해결합니다. 이 전략은 추가적인 다중 헤드 쿼리와 공유 키를 사용하여 RoPE를 처리하며, 이를 통해 추론 중 모든 접두사 토큰에 대한 키를 재계산해야 하는 부담을 줄입니다. 이로 인해 MLA는 추론 효율성을 크게 향상시킬 수 있습니다. [1]

3.2 ITME

ITME는 CXL-hybrid 메모리를 활용하여 대규모의 바이트 주소 가능 원격 메모리 확장을 제공합니다. 이 시스템은 데이터 이동을 관리하기 위해 파이프라인 방식의 다중 계층 DMA 기반 접근 방식을 구현하며, 이는 모델 가중치와 프리픽스 캐시의 결정론적 접근 패턴을 활용하여

메모리-스토리지 계층 간의 데이터 이동을 효율적으로 관리합니다. 이러한 방식은 읽기 우선 스케줄링을 통해 I/O 병목 현상을 완화하고, 극심한 경쟁 상황에서도 원격 계층에서 데이터를 검색하는 것이 전체 재계산보다 훨씬 효율적임을 보여줍니다. [2]

ITME의 프로토타입 검증 범위는 기존 소프트웨어 정책과의 호환성을 포함하여, 다양한 스케줄링 정책과의 시너지를 통해 시스템 효율성을 극대화하는 것입니다. ITME는 기존의 계층화 메커니즘과 원활하게 통합되며, 내부 하드웨어 수준의 프리패칭을 통해 데이터 접근 지연을 숨기고, 진행 중인 계산과 데이터 이동을 겹치게 하여 KV 캐시 재사용을 극대화합니다. 이러한 검증 과정에서 ITME는 성능 변동이 있을 수 있지만, 전반적으로 CPU 오프로드 기준 대비 최대 35.7%의 처리량 향상을 달성합니다. [2]

4. 관점별 평가

4.1 기술 성숙도 및 TRL

DeepSeek-V2의 논문에서는 실험 결과와 공개 배포가 이루어졌으나, MLA 구성요소의 실제 운영 검증에 대한 근거가 부족하다. 따라서 TRL 8~9로의 확정은 유보된다. 이 정보는 DeepSeek-V2의 성능 평가와 관련된 페이지에서 확인할 수 있다. [1]

ITME의 FPGA 프로토타입은 하드웨어의 실행 가능성을 입증하였으나, 실제 운영에 대한 증거가 부족하다. 따라서 TRL 6으로 잠정 추정된다. 이 내용은 ITME의 성능 평가와 관련된 페이지에서 확인할 수 있다. [2]

4.2 시장성

DeepSeek-V2 모델은 공개된 자료에 따르면, MoE와 MLA 아키텍처를 활용하여 효율적인 훈련과 추론을 가능하게 하고 있습니다. 그러나 DeepSeek-V2의 실제 채택률에 대한 구체적인 데이터는 부족하며, 공개된 자료에서 모델의 성능이나 채택에 대한 명확한 지표를 찾기 어렵습니다. 이는 DeepSeek-V2의 시장 내 위치와 수용 가능성을 평가하는 데 한계를 초래합니다. [3] [4] [5]

CXL 기술은 메모리, 스토리지 및 로직 칩과 같은 다양한 장치의 인터페이스를 통합하여 시스템의 대역폭과 처리 능력을 증가시키는 데 주목받고 있습니다. 그러나 CXL 공급자들이 공개한 제품 및 생태계에 대한 정보는 제한적이며, ITME의 채택에 대한 구체적인 증거도 부족합니다. 이러한 상황은 CXL 기술의 상용화 및 실제 적용 가능성을 평가하는 데 어려움을 줍니다. [7] [8] [9]

4.3 이해관계자

LLM 및 서비스 개발자들은 모델의 접근성과 언어 지원, 환각 검증 요구에 대해 우려하고 있습니다. DeepSeek-V2는 중국어와 영어 콘텐츠에 주로 기반하고 있어, 다른 언어에 대한 능력이 제한적일 수 있습니다. 또한, LLM의 일반적인 한계로는 사전 훈련 이후 지속적인 지식 업데이트 부족, 검증되지 않은 조언과 같은 비사실 정보 생성 가능성, 환각 발생 가능성이 있습니다. 이러한 요소들은 모델의 신뢰성과 활용도를 저하시킬 수 있으므로, 개발자들은 이러한 문제를 해결하기 위한 검증 절차를 요구하고 있습니다. [6] [10]

클라우드 운영자와 메모리 공급자들은 호환성, 투자, 지연 검증 요구에 대해 주목하고 있습니다. 클라우드 서비스의 경제성을 평가할 때, 기업들은 직접 및 간접 비용을 모두 고려해야 하며, 이는 데이터 전송 비용, 아키텍처 설계, 직원 및 컨설팅 비용 등을 포함합니다. 또한, 클라우드 마이그레이션 과정에서 발생할 수 있는 숨겨진 비용, 예를 들어 다운타임이나 생산성 손실 등도 중요한 요소로 작용합니다. 이러한 요구는 클라우드 인프라의 효율성을 높이고, 투자 결정을 지원하기 위한 필수적인 검증 절차로 간주됩니다. [11]

4.4 데이터센터-클라우드 적용성

DeepSeek-V2는 Multi-head Latent Attention(MLA) 아키텍처를 통해 Key-Value(KV) 메모리의 효율적인 압축을 보장하며, 긴 입력과 동시성, 정확도 검증을 수행합니다. 이 모델은 236B의 총 매개변수를 가지고 있으며, 각 토큰에 대해 21B가 활성화됩니다. MLA는 KV 캐시를 잠재 벡터로 압축하여 효율적인 추론을 가능하게 합니다. [1]

ITME는 GPU-확장 메모리 이동을 통해 I/O 지연을 줄이고 호환성을 검증합니다. ITME는 CXL-하이브리드 메모리 장치에서 GPU 메모리의 원활한 데이터 이동을 위한 파이프라인 기반의 다계층 DMA 프리패칭을 구현합니다. ITME의 성능은 SK Hynix CMM 및 PCIe Gen5 NVMe SSD를 사용하여 검증되었으며, CPU 오프로드 대비 최대 35.7%의 처리량 향상을 달성했습니다. 이 수치는 원문 실험의 CPU 오프로드 대비 수치이며, 일반 운영 효과가 아닙니다. [2]

5. 관점별 비교 및 상충 지점

DeepSeek-V2와 ITME는 서로 다른 아키텍처와 접근 방식을 가지고 있으며, 특정 상황에서 서로 경쟁할 수 있습니다. DeepSeek-V2는 Multi-head Latent Attention(MLA) 기술을 통해 긴 컨텍스트 처리에 강점을 보이는 반면, ITME는 CXL-hybrid 메모리를 활용하여 메모리 확장을 중점적으로 다룹니다. 이러한 기술적 차이는 각 기술의 성능이 특정 조건에 따라 달라질 수 있음을 시사합니다. 예를 들어, DeepSeek-V2는 긴 문맥을 처리하는 데 최적화되어 있어 대규모 데이터셋을 다룰 때 유리할 수 있습니다. 반면, ITME는 메모리 용량을 확장하는 데 중점을 두어, 메모리 집약적인 작업에서 성능을 발휘할 수 있습니다. 그러나 두 기술의 직접 비교는 실험 단위와 시스템 계층의 차이로 인해 위험할 수 있으며, 각 기술의 성능을 평가하기 위해서는 동일한 조건에서의 실험이 필요합니다. 따라서, 두 기술의 성능을 비교할 때는 이러한 차이를 충분히 고려해야 합니다. [1]

두 기술의 비교는 동일한 목표를 서로 다른 계층에서 다루는지부터 구분해야 한다. DeepSeek-V2 MLA는 모델의 어텐션과 KV 표현 방식을 바꾸는 접근이고, ITME는 HBM과 확장 메모리 사이의 배치·이동 경로를 다루는 접근이다. 따라서 메모리 사용량, 긴 컨텍스트, 동시 요청 처리, 데이터 이동 지연, 구현 복잡도는 비교 가능한 항목이지만 동일한 실험 조건에서 측정되지 않았다면 수치를 바로 대조할 수 없다. 한 기술의 논문 수치가 다른 기술보다 크거나 작다는 사실만으로 전체적인 우열을 판단하는 것도 적절하지 않다. 각 결과가 어떤 모델, 하드웨어, 입력 길이, 동시성, 소프트웨어 버전에서 측정됐는지를 함께 확인해야 한다.

두 접근은 경쟁 관계로만 볼 필요도 없다. 모델 내부의 KV 표현을 줄이는 방식과 외부 메모리 계층을 확장하는 방식은 동일한 시스템에서 서로 다른 병목을 완화할 가능성이 있지만, 실제 결합 가능성은 구현 호환성과 데이터 이동 비용을 별도로 검증해야 한다. 비교의 핵심은 전체적인 우열을 정하는 것이 아니라 어떤 조건에서 어떤 병목이 남는지 확인하는 데 있다. 후속 검증에서는 동일한 모델과 입력 집합을 사용해 HBM 사용량, TTFT, 처리량, tail latency, 정확도, 메모리 이동량을 같은 측정 절차로 기록해야 한다. 그 결과가 확보되기 전까지는 공개 자료가 보여주는 장점과 실제 운영 효과를 구분해 해석해야 한다.

6. 시사점

기술 선택에 있어서는 단순히 특정 기술을 추천하기보다는, 어떤 서빙 조건에서 어떤 검증 질문을 우선해야 하는지에 대한 명확한 기준이 필요합니다. 이를 위해 PoC(Proof of Concept) 및 벤치마크 후속 과제를 통해 각 기술의 성능을 검증하고, 실제 운영 환경에서의 적용 가능성을 평가해야 합니다. 또한, DeepSeek-V2와 ITME의 조합 사용 가능성을 탐색하여 성능 향상을 도모할 수 있습니다. 이러한 접근은 각 기술의 강점을 최대한 활용할 수 있는 기회를 제공할 것입니다. 그러나 이러한 검증 과정에서 발생할 수 있는 변수와 불확실성을 고려해야 하며, 각 기술의 성능이 특정 조건에 따라 달라질 수 있음을 인지해야 합니다. 따라서, 기술 선택 시에는 다양한 실험 결과와 시장 반응을 종합적으로 분석하는 것이 중요합니다. [1]

이 분석의 시사점은 두 기술 중 하나를 선택하는 결론이 아니라, 적용 조건에 따라 무엇을 먼저 검증해야 하는지를 정리하는 데 있다. MLA처럼 모델 내부의 KV 표현과 저장량을 바꾸는 접근은 모델 구조, 어텐션 구현, 긴 컨텍스트 길이, 동시 요청 수를 함께 확인해야 한다. ITME처럼 메모리 계층과 데이터 이동 경로를 바꾸는 접근은 HBM과 CXL 사이의 이동량, 접근 지연, 대역폭, 버퍼 관리, 장치 호환성을 별도로 확인해야 한다. 따라서 공개 자료에서 확인된 원리나 프로토타입 결과를 실제 서비스의 처리량과 비용으로 바로 일반화해서는 안 된다. 두 접근을 검토할 때에는 먼저 동일한 모델, 하드웨어, 소프트웨어 버전, 입력 길이, 동시성 조건을 고정한 기준선을 마련해야 한다. 그 다음 KV cache 사용량, HBM 점유량, 첫 토큰 지연시간, 토큰 처리량, tail latency, 데이터 이동량, 정확도 변화를 같은 방식으로 측정해야 한다. 결과가 확인되더라도 운영 복잡도와 장애 대응 방식, 기존 서빙 스택과의 호환성, 추가 장비 및 개발 비용을 함께 기록해야 한다. 이런 절차를 거쳐야만 기술의 장점과 제약을 동일한 판단 단위에서 비교할 수 있다.

후속 PoC에서는 기술별로 확인 가능한 주장과 아직 공개 정보가 부족한 주장을 분리해 실험 계획에 반영해야 한다. 예를 들어 짧은 입력과 긴 입력, 낮은 동시성과 높은 동시성, 캐시 적중과 캐시 교체가 많은 상황을 나누어 측정하면 특정 조건에만 나타나는 효과를 구분할 수 있다. 또한 단일 평균값만 기록하지 말고 반복 측정의 분산과 최악 구간을 함께 기록해야 한다. 모델 정확도나 응답 품질이 유지되는지도 같은 질의 집합으로 확인해야 하며, 메모리 절감이 실제 비용 절감으로 이어지는지는 인프라 가격과 운영 정책을 포함해 별도로 계산해야 한다. 현재 자료만으로는 이 후속 결과를 확정할 수 없으므로, 본 보고서의 시사점은 의사결정의 방향이 아니라 검증 우선순위와 측정 항목을 제안하는 수준으로 해석해야 한다.

7. 분석의 한계

본 보고서에서 사용된 논문 및 웹 자료의 범위가 제한적이며, 실험 조건의 불일치로 인해 결과의 일반화에 한계가 있습니다. 공개되지 않은 비용, 운영 및 상용화 정보가 부족하여 추가 검증이 필요합니다. 특히, LLM(대형 언어 모델) 생성 해석의 한계로 인해 기술의 실제 성능을 정확히 평가하기 어려운 점도 고려해야 합니다. 또한, DeepSeek-V2와 ITME 모두 독립적인 출처에서의 교차 검증이 부족하여 시장 채택

에 대한 확정적인 결론을 내리기 어렵습니다. 이러한 정보 부족은 기술의 실제 운영 효과를 평가하는 데 있어 중요한 제약 요소로 작용할 수 있습니다. 따라서, 향후 연구에서는 보다 다양한 출처와 조건에서의 검증이 필요할 것입니다. [1]

본 분석의 한계는 근거가 없다는 사실과 기술이 존재하지 않는다는 판단을 구분해야 한다는 점에서 시작한다. 현재 보고서는 제공된 논문과 검색된 공개 자료를 바탕으로 작성되었으며, 모든 구현 버전, 내부 운영 지표, 계약 조건, 실제 구매 비용과 상용 서비스의 세부 설정을 확인한 것은 아니다. 논문마다 모델 크기, 하드웨어, 입력 길이, 동시성, 측정 방법이 다를 수 있으므로 서로 다른 실험의 수치를 직접 비교하면 해석이 왜곡될 수 있다. 웹 자료는 게시 시점과 검색 결과의 품질에 영향을 받으며, 자료가 갱신되거나 접근이 제한될 가능성도 있다. 또한 검색된 자료에 특정 관점의 정보가 더 많이 포함되면 시장성이나 이해관계자 분석이 실제보다 풍부하게 보일 수 있다. 이 보고서의 문장은 입력된 근거를 요약하고 연결한 결과이므로, 원문이 말하지 않은 운영 효과나 도입 가능성을 사실처럼 확정하지 않아야 한다. 등록되지 않은 근거 ID가 붙은 주장은 제외했으며, 이는 해당 주장이 거짓이라는 뜻이 아니라 현재 자료로 완전히 추적할 수 없다는 뜻이다.

따라서 최종 판단 전에 원문 페이지와 웹 출처를 사람이 다시 대조하고, 동일 조건의 재현 실험을 수행해야 한다. 재현 실험에는 모델과 라이브러리 버전, 하드웨어 구성, 입력 분포, 동시 요청 수, warm-up 방식, 캐시 정책, 측정 구간을 명시해야 한다. 공개 자료에서 확인되지 않는 비용과 운영 난이도는 공급자 자료나 PoC 로그로 보완해야 하며, 단일 실험 결과를 일반적인 우열 판단으로 확대하지 않아야 한다. 추가 자료가 확보되면 기존 결론을 그대로 유지하기보다 주장별 근거 연결과 조건을 다시 점검해야 한다. 이 한계 때문에 본 보고서는 기술 선택을 확정하는 문서가 아니라, 공개 근거를 기준으로 비교 가능한 항목과 추가 검증이 필요한 항목을 구분한 사전 평가로 보는 것이 적절하다.

REFERENCE

- [1] DeepSeek-AI(2024). DeepSeek-V2: A Strong, Economical, and Efficient Mixture-of-Experts Language Model. arXiv:2405.04434. (pp.1, 2, 7, 8, 15, 19)
- [2] Jang, H., Min, Y., Kim, S., Ahn, T., Kim, H., Joo, Y., Kim, H., & Kim, J.(2026). ITME: Inference Tiered Memory Expansion with Disaggregated CXL-Hybrid Memories. arXiv:2606.12556. (pp.1, 9, 10, 11)
- [3] www.turingpost.com(2024-08-28). Inside DeepSeek Models: MoE, MLA, and Coder-V2 Explained, <https://www.turingpost.com/p/deepseek>
- [4] huggingface.co(날짜 미상). DeepSeek-V2 · Hugging Face, https://huggingface.co/docs/transformers/model_doc/deepseek_v2
- [5] cryptorank.io(2025-01-29). Meet Luo Fuli: The AI pro behind DeepSeek's open-source model and MLA technology | AI OpenAI | CryptoRank.io, <https://cryptorank.io/news/feed/29815-meet-luo-fuli-ai-expert-behind-deepseek-mla>
- [6] arxiv.org(날짜 미상). DeepSeek-V2, <https://arxiv.org/pdf/2405.04434>
- [7] news.skynix.com(날짜 미상). SK hynix Presents CXL Memory Solutions Set to Power the AI Era at CXL DevCon 2024 - SK hynix Newsroom, <https://news.skynix.com/en/sk-hynix-presents-ai-memory-solutions-at-cxl-devcon-2024>
- [8] arxiv.org(날짜 미상). HyMCache: A KV Cache Framework for Multi-Turn LLM Serving with CXL-Hybrid Memory, <https://arxiv.org/html/2607.18141v2>
- [9] semiconductor.samsung.com(2026-09-04). Breaking AI Memory Limits with CXL Memory Pooling, <https://semiconductor.samsung.com/news-events/tech-blog/breaking-ai-memory-limits-with-cxl-memory-pooling>
- [10] newsletter.semianalysis.com(2025-01-31). DeepSeek Debates: Chinese Leadership On Cost, True Training Cost, Closed Model Margin Impacts, <https://newsletter.semianalysis.com/p/deepseek-debates>
- [11] www.oracle.com(2024-01-25). Cloud Computing Costs in 2024, <https://www.oracle.com/cloud/cloud-computing-cost>